академия больших данных mail.ru group

Настоящий блок лекций подготовлен при поддержке «ЦРТ | Группа компаний»

Обработка речевых сигналов

Блок 2. Автоматическое распознавание речи

Максим Кореневский

Старший научный сотрудник

ООО «ЦРТ-инновации», к.ф.-м.н.

Блок 2. Автоматическое распознавание речи (Automatic Speech Recognition, ASR)

Часть 3. Системы распознавания речи на основе GMM-HMM

Напоминание: архитектура (традиционной) ASR-системы

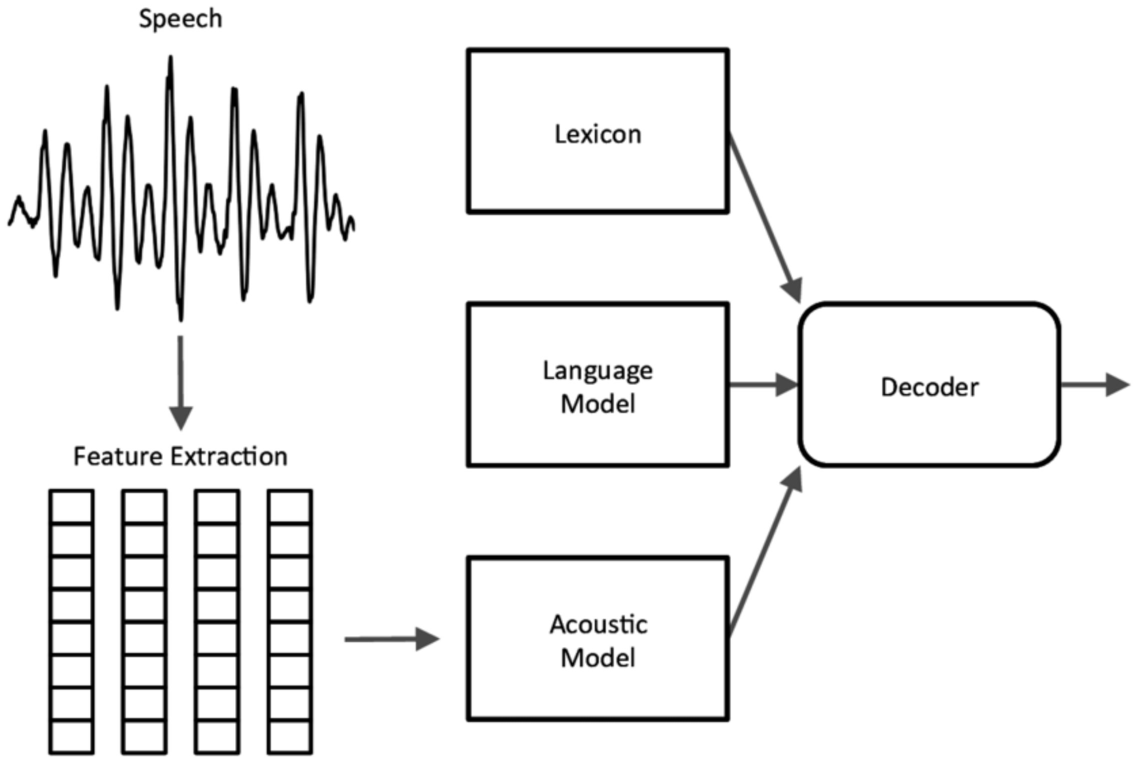

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

Скрытая Марковская модель (Hidden Markov Model, HMM)

- Скрытая Марковская модель: $\lambda = (\pi, A, B)$
  - $\pi_i = P(q_1 = s_i)$ – начальные вероятности
  - $a_{ij} = P\left(q_t = s_j \middle| q_{t-1} = s_i\right)$ - вероятности переходов
  - Состояния процесса **не наблюдаются** непосредственно
  - Есть множество наблюдаемых значений V
  - В каждом состоянии задано вероятностное распределение наблюдаемых в нем значений:

    $V = \{v_1, v_2, \ldots, v_M\}$ - множество значений, $b_{jk} = b_j(v_k) = P\left(o_t = v_k \middle| q_t = s_j\right)$ - наборы вероятностей,
  - B – набор этих вероятностных распределений: $B = \{b_j\}$
  - Распределения могут быть и непрерывными: $b_j(o_t) = p\left(o_t \middle| q_t = s_j\right)$ - плотности, а не вероятности
- Отдельные наблюдения при фиксированных состояниях НЕЗАВИСИМЫ (frame independence assumption)

НММ – генеративная модель

- НММ может использоваться для генерации последовательности наблюдений $O = (o_1, o_2, \ldots, o_T)$:
  1. Положить $t = 1$
  2. Выбрать начальное состояние $q_1 = s_i$ в соответствии с распределением $\{\pi_i\}$
  3. Сгенерировать наблюдение $o_t = v_k$ в соответствии с распределением $\{b_i\}$ в текущем состоянии
  4. Выбрать следующее состояние $q_{t+1} = s_j$ в соответствии с распределением $\{a_{ij}\}$
  5. Положить $t = t + 1$ и перейти к шагу 3, если $t \leq T$
- Примерно так работает «аппарат» в примере с урнами

Скрытая Марковская модель

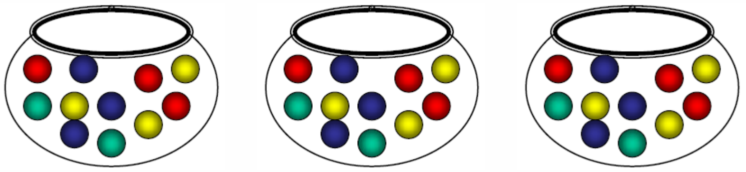

Пример с урнами и шарами (напоминание)

- Есть 3 урны, в каждой из которых определенное (известное?) количество шаров красного, синего и зеленого цвета. И есть некий «аппарат»:
    1. Вначале аппарат выбирает урну наугад в соответствии с некими вероятностями π_i
    2. После этого аппарат достает из урны случайно выбранный шар, записывает его цвет и возвращает обратно
    3. После этого аппарат выбирает, к какой урне переместиться согласно распределению a_{ij}
    4. Шаги 2-3 повторяются некоторое количество раз
- Наблюдатель видит только последовательность цветов, записанную аппаратом. Номера урн он не знает! Хочется уметь отвечать на вопросы:
    - Какова вероятность выбранной последовательности цветов?
    - Какой последовательности урн она наиболее вероятно соответствует?
    - Если содержимое урн и вероятности π_i и a_{ij} неизвестны, как их оценить по имеющимся записанным последовательностям цветов? Т.е. как **обучить** модель, используя наблюдения ?

Скрытые Марковские модели и связанные задачи

1. Вероятность последовательности наблюдений

- Есть последовательность наблюдений $O = (o_1, o_2, \dots, o_T)$. Как найти $P(O|\lambda)$?
- Рассмотрим всевозможные последовательности состояний $q = (q_1, q_2, \dots, q_T)$

$$P(q|\lambda) = \pi_{q_1} \cdot a_{q_1 q_2} \cdot a_{q_2 q_3} \cdots a_{q_{T-1} q_T}$$

- Вероятность наблюдений на заданной последовательности состояний

$$P(O|q,\lambda) = \prod_{t=1}^{T} P(o_t|q_t,\lambda) = b_{q_1}(o_1) \cdot b_{q_2}(o_2) \cdots b_{q_T}(o_T)$$

- По формуле полной вероятности:

$$P(O|\lambda) = \sum_q P(O,q|\lambda) = \sum_q P(O|q,\lambda) P(q|\lambda) = \sum_q \pi_{q_1} b_{q_1}(o_1) a_{q_1 q_2} b_{q_2}(o_2) a_{q_2 q_3} \cdots a_{q_{T-1} q_T} b_{q_T}(o_T).$$

Скрытые Марковские модели и связанные задачи

Forward-алгоритм

- Введем вспомогательную величину (forward-вероятность): $\alpha_t(i) = P(o_1 o_2 \dots o_t, q_t = s_i | \lambda)$
- Несложно понять, что ее можно вычислять рекуррентно:

$$\alpha_1(i) = \pi_i b_i(o_1)$$

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^{N} \alpha_t(i) a_{ij} \right] b_j(o_{t+1})$$

- Если вычислены значения $\alpha_T(i)$ во всех состояниях, то

$$P(O|\lambda) = \sum_{i=1}^{N} \alpha_T(i).$$

- Этот алгоритм позволяет вычислять $P(O|\lambda)$ за $O(TN^2)$ операций

Скрытые Марковские модели и связанные задачи

Forward-алгоритм: иллюстрация

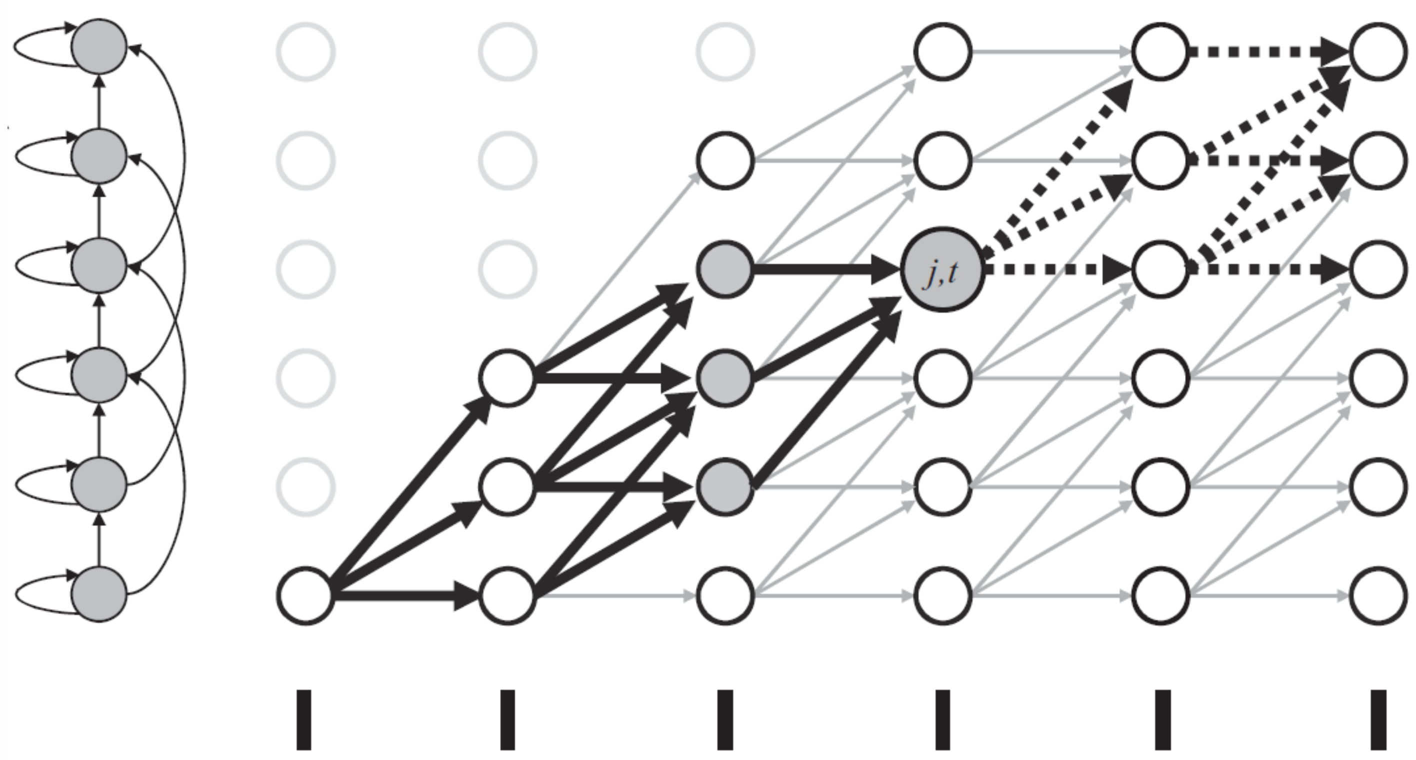

Скрытые Марковские модели и связанные задачи

Backward-алгоритм (аналог в обратную сторону)

- Введем аналогичную величину (backward-вероятность): $\beta_t(i) = P(o_{t+1} o_{t+2} \dots o_T | q_t = s_i, \lambda)$
- Ее тоже можно вычислять рекуррентно:

$$\beta_T(i) = 1, \qquad \beta_t(i) = \sum_{i=1}^{N} a_{ij}\, b_j(o_{t+1}) \beta_{t+1}(j),$$

$$P(O|\lambda) = \sum_{i=1}^{N} \pi_i b_i(o_1) \beta_1(i).$$

- С помощью forward и backward-вероятностей можно вычислить вероятности прохода через данное состояние в данный момент времени:

$$P(O, q_t = s_i | \lambda) = P(o_1 o_{t+2} \dots o_T, q_t = s_i | \lambda) = \alpha_t(i) \beta_t(i)$$

Скрытые Марковские модели и связанные задачи

2. Вычисление наилучшей последовательности состояний:

- Есть последовательность наблюдений $O = (o_1, o_2, \dots, o_T)$. На какой последовательности состояний $\hat{q} = (q_1, q_2, \dots, q_T)$ она наиболее вероятно наблюдается?

$$\hat{q} = \operatorname*{argmax}_q P(O, q|\lambda)$$

- Динамическое программирование: определим вспомогательную величину

$$\delta_t(i) = \max_{q_1 q_2 \dots q_{t-1}} P(q_1 q_2 \dots q_{t-1}, q_t = s_i, o_1 o_2 \dots o_t|\lambda) \,.$$

- Ее можно пересчитывать рекуррентно (алгоритм Витерби, A.Viterbi, 1972):

$$\delta_1(i) = \pi_i b_i(o_1), \qquad \delta_{t+1}(j) = \max_i \left(\delta_t(i) a_{ij}\right) b_j(o_{t+1})$$

- Если на каждом шаге запоминать из какого состояния $\varphi_t(i)$ мы пришли в данное, то можно восстановить оптимальную последовательность состояний (выравнивание).
- Эту процедуру еще называют forced alignment.

Скрытые Марковские модели и связанные задачи

Алгоритм Витерби (более подробно):

- Инициализация: $\delta_1(i) = \pi_i b_i(o_1), \quad \varphi_1(i) = 0, \quad i = 1,2,\dots,N$
- Рекурсия: $\delta_t(j) = \max_i \left(\delta_{t-1}(i) a_{ij}\right) b_j(o_t),$

  $\varphi_t(j) = \operatorname{argmax}_i \left(\delta_{t-1}(i) a_{ij}\right) b_j(o_t), \qquad i = 1,2,\dots,N, \qquad t = 2,\dots,T$
- Завершение: $P^* = \max_i \left(\delta_T(i)\right), \qquad \hat{q}_T = \operatorname{argmax}_i \left(\delta_T(i)\right)$
- Обратный ход (восстановление последовательности состояний): $\hat{q}_t = \varphi_{t+1}(\hat{q}_{t+1})$
- NB: Лучше все вычисления производить в логарифмах (произведения → суммы)

3. Обучение Скрытой Марковской модели

- Пусть наша HMM должна описывать конкретное слово и есть набор «эталонов» этого слова. Как найти наилучшие параметры модели?
- Метод максимального правдоподобия: выбрать такие параметры, для которых достигается максимальная суммарная вероятность на эталонах

$$\hat{\lambda} = \underset{\lambda}{\operatorname{argmax}}\, P(O|\lambda)$$

- Нет эффективного алгоритма для поиска глобального максимума ☹
- Приходится использовать итерационные подходы. Два самых распространенных:
  - Витерби-обучение
  - Алгоритм Баума-Уэлша (Baum-Welch algorithm).
  - Оба варианта - разновидности EM-алгоритма. На каждой итерации происходит обновление параметров модели: $\lambda \rightarrow \bar{\lambda}$, при котором вероятность гарантированно НЕ УБЫВАЕТ!

Скрытые Марковские модели и связанные задачи

Витерби обучение:

- Предположим, что у нас есть разметка наблюдений на состояния HMM:

Разметка речи на состояния моделей фонем

Витерби обучение:

- Тогда мы можем набрать статистику и оценить параметры HMM:

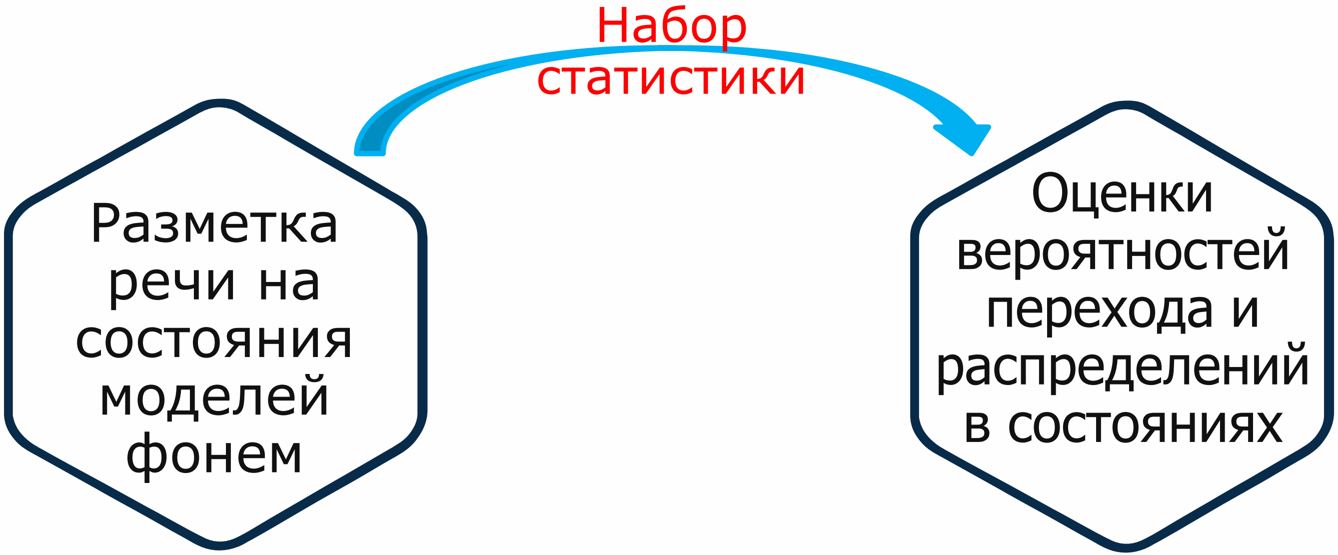

Скрытые Марковские модели и связанные задачи

Витерби обучение:

- Предположим теперь, что у нас есть данные и описывающая их HMM:

Оценки вероятностей перехода и распределений в состояниях

Скрытые Марковские модели и связанные задачи

Витерби обучение:

- Тогда мы можем найти наилучшее выравнивание данных алгоритмом Витерби (forced alignment, каждому наблюдению сопоставим состояние HMM):

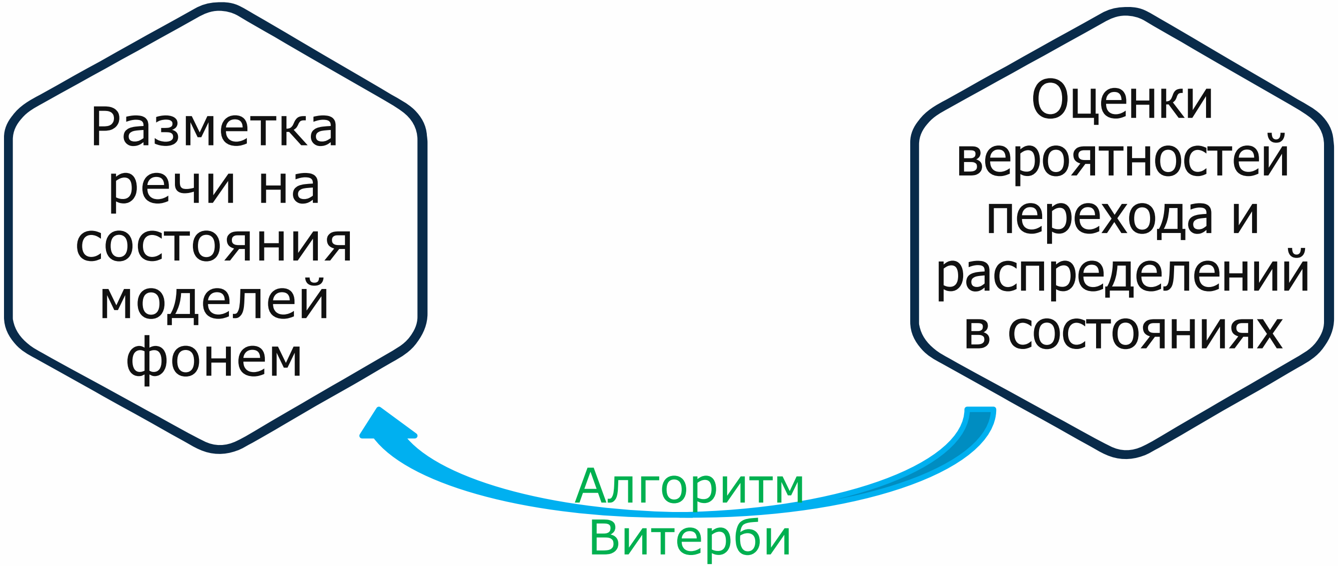

Скрытые Марковские модели и связанные задачи

Витерби обучение:

- Значит можно организовать итерационную процедуру:

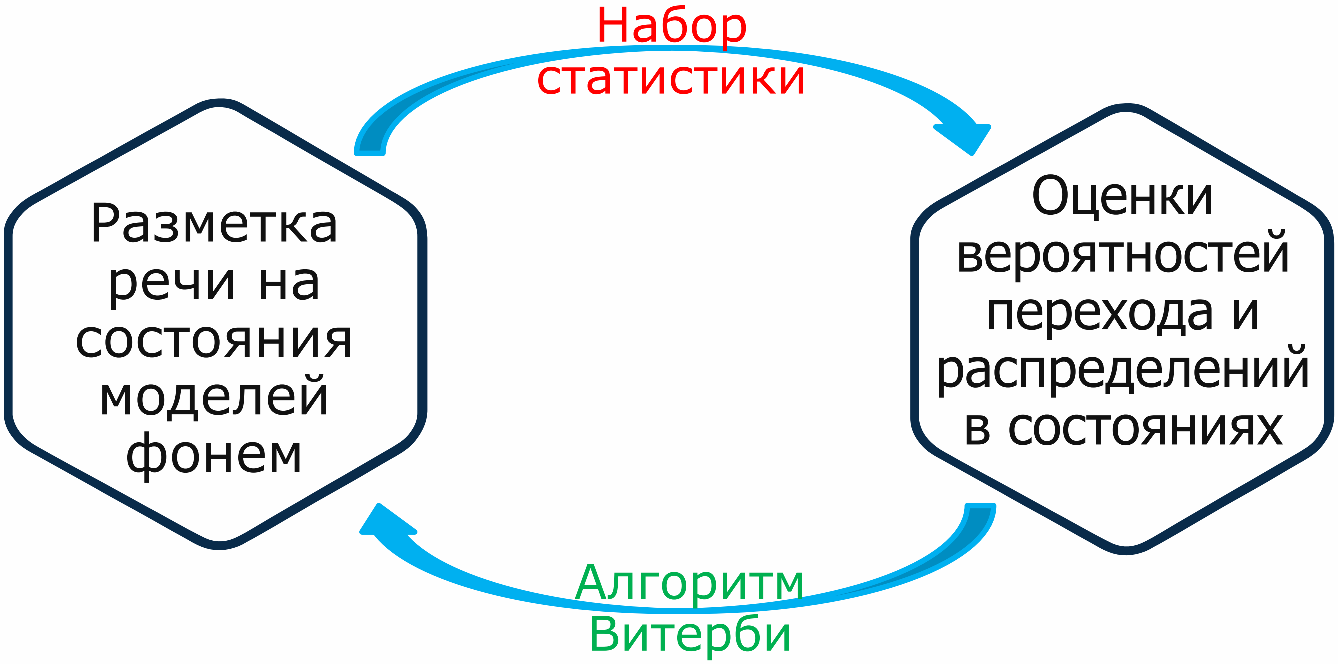

Скрытые Марковские модели и связанные задачи

Алгоритм Баума-Уэлша (E-шаг):

- Используя текущие значения параметров модели λ, вычисляются вероятности:
  - Вероятность в момент времени t находиться в состоянии s_i на данной последовательности наблюдений (state occupancy probability):

$$\gamma_i(t) = P(s(t) = s_i |\, o_1, o_2, \dots, o_T; \lambda)$$

  - Вероятность в момент времени t находиться в состоянии s_i, а в момент времени $(t+1)$ - в состоянии s_j:

$$\xi_{ij}(t) = P(s(t) = s_i, s(t+1) = s_j |\, o_1, o_2, \dots, o_T; \lambda)$$

- Их можно вычислить, используя forward и backward-вероятности:

$$\gamma_i(t) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_j \alpha_t(j)\beta_t(j)}$$

$$\xi_{ij}(t) = \frac{\alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}{P(O|\lambda)} = \frac{\gamma_i(t)a_{ij}b_j(o_{t+1})\beta_{t+1}(i)}{\beta_t(i)}$$

Алгоритм Баума-Уэлша (М-шаг) для дискретной НММ:

- На М-шаге происходит обновление параметров НММ:

$$\pi_i = \gamma_1(i), \qquad a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_{ij}(t)}{\sum_{t=1}^{T-1} \gamma_i(t)}$$

$$b_{jk} = b_j(v_k) = \frac{\sum_{t:o_t=v_k} \gamma_j(t)}{\sum_t \gamma_j(t)}$$

- Если эталонов, по которым строится НММ, несколько (N), то вероятности $\gamma_i(t)$ и $\xi_{ij}(t)$ вычисляются для каждого эталона в отдельности, а в формулы добавляется суммирование по всем эталонам:

$$\pi_i = \frac{\sum_n \gamma_1^{(n)}(i)}{N}, \qquad a_{ij} = \frac{\sum_n \sum_{t=1}^{T-1} \xi_{ij}^{(n)}(t)}{\sum_n \sum_{t=1}^{T-1} \gamma_i^{(n)}(t)}, \qquad b_{jk} = \frac{\sum_n \sum_{t:o_t=v_k} \gamma_j^{(n)}(t)}{\sum_n \sum_t \gamma_j^{(n)}(t)}$$

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

Недостатки построения HMM для отдельных слов

- Много состояний, много параметров («тяжелые» модели)
- С ростом размера словаря становится слишком затратным
- На каждое слово в обучающих данных может быть слишком мало примеров, как следствие – переобучение
- Выход: перейти на суб-словные единицы: слоги, фонемы.
  - Фонем в большинстве языков относительно немного (не более 100)
  - На каждую фонему значительно больше статистики
  - «Топология» HMM для фонем может быть очень простой.
  - Типичный вариант фонемной HMM: 3 state, left-to-right

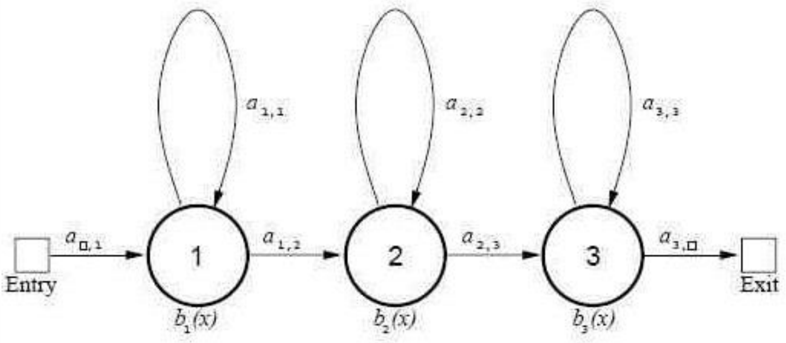

Фонемные HMM и способы их улучшения

- Как учить фонемные HMM?
  - Фонемные HMM «склеиваются» в словные HMM, а они – в HMM для целой фразы

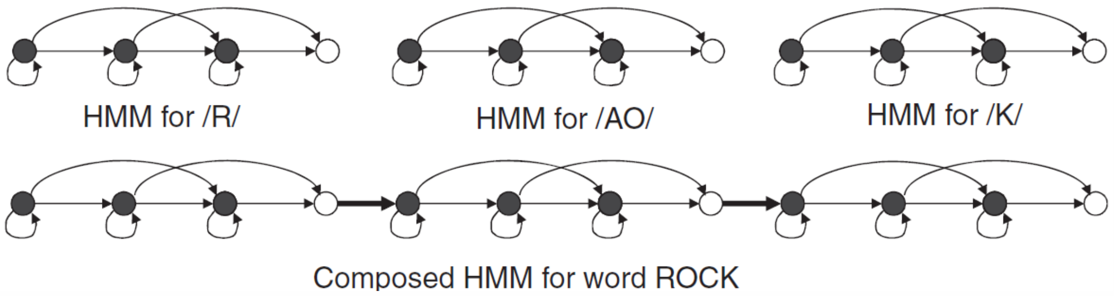

  - Одинаковые состояния одинаковых фонем «разделяют» (share) общие параметры
  - При обучении надо накапливать статистики для состояний по всем вхождениям
- Типичное количество состояний: 150-200
- Основная проблема – в разном окружении фонемы сильно различаются: фонема «т» в слове «вата» совсем не такая, как в слове «строить». Это называется коартикуляцией

Учет фонетического контекста

- Фонема в определенном «окружении» называется аллофоном.
- Аллофон с контекстом в 1 фонему слева и справа называется трифоном.
- Фонемная запись: вата => v a0 t a4 (a0 – ударная, a4 – на конце слова)
- Трифонная запись: вата => v+a0 v-a0+t a0-t+a4 t-a4:
  - Трифон v-a0+t – это аллофон фонемы a0, которая находится в окружении v слева и t справа
  - Дифон v+a0 – это аллофон фонемы v справа от которой стоит фонема a0
  - Дифон t-a4 – это аллофон фонемы a4, слева от которой стоит фонема t
- При склеивании словных HMM следует учитывать влияние «межсловного» контекста («город Москва» vs. «город Санкт-Петербург»)
- Используют также «пентафоны» (или quinphones) - аллофоны с контекстом 2 фонемы с каждой стороны

Учет фонетического контекста

- Фонема в определенном «окружении» называется аллофоном.
- Аллофон с контекстом в 1 фонему слева и справа называется трифоном.

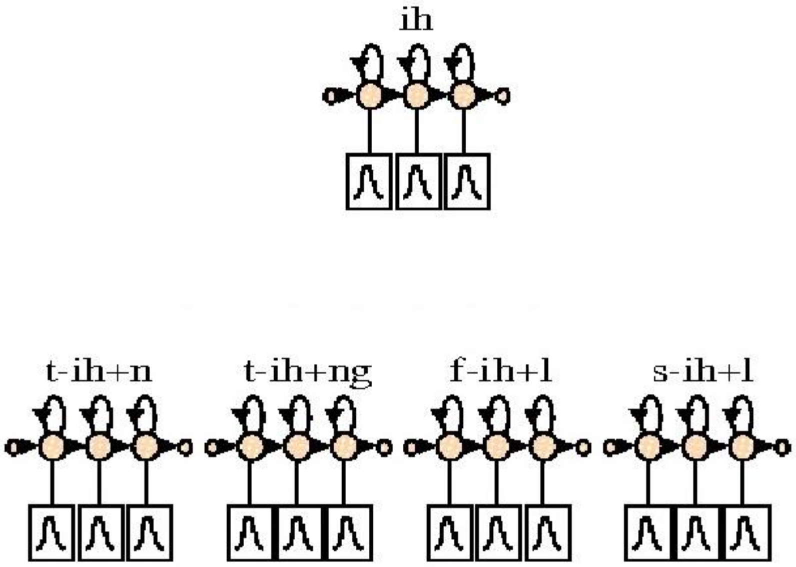

Проблемы трифонных моделей

- Различных трифонов <u>очень много</u>. Если фонем 50, то трифонов 125000.
- Очень многие трифоны из полного набора вообще никогда не встречаются в речи, очень многих в обучающих данных нет вообще или очень мало!
- Чтобы сохранить число параметров в разумных пределах придумали связывать (tie) похожие состояния трифонов. Связанные состояния (сеноны, senones) разделяют (share) общее распределение в состоянии.

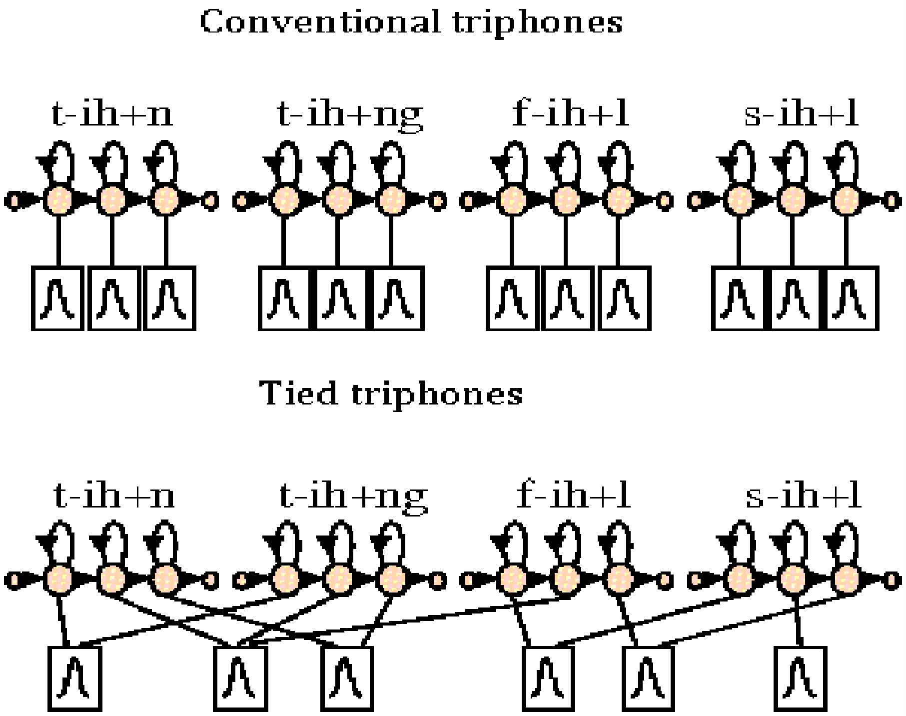

Связывание состояний. Деревья решений

- Как правило, связывают трифоны, относящиеся к одной фонеме.
- Связывание обычно проводят по дереву решений (decision tree).
- Дерево строится путем разбиения всего множества трифонов на классы в соответствие с «вопросами».
- Число связанных состояний – обычно 5-10 тысяч.

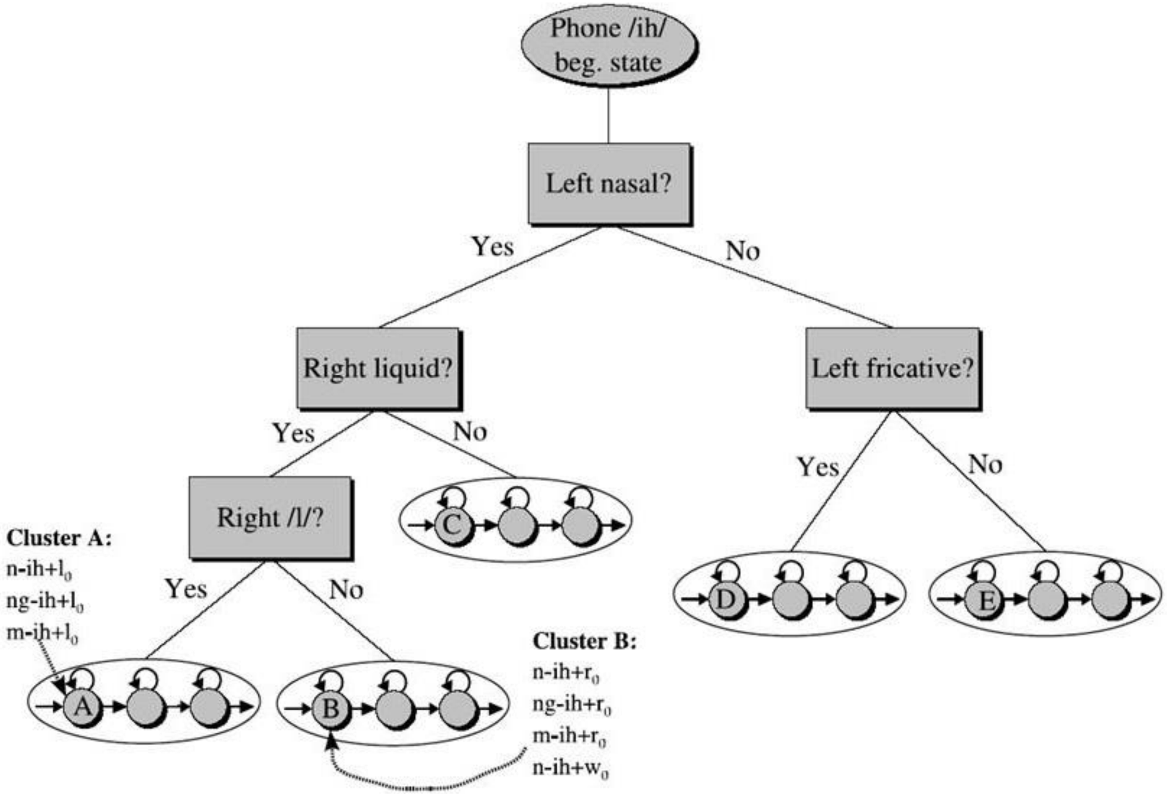

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

Гауссова смесь (Gaussian Mixture Model, GMM)

Непрерывные распределения в состояниях HMM:

- До сих пор мы рассматривали только дискретные распределения в состояниях
- Но часто наблюдения распределены непрерывно (например, MFCC-признаки)
- Можно провести векторное квантование и свести задачу к дискретной, но это «сжатие с потерями» и оно снижает качество
- Вероятности наблюдений в состояниях заменяются на плотности распределения: $b_j(o_t) = p\left(o_t \middle| q_t = S_j\right)$
- Как использовать непрерывные распределения на практике?

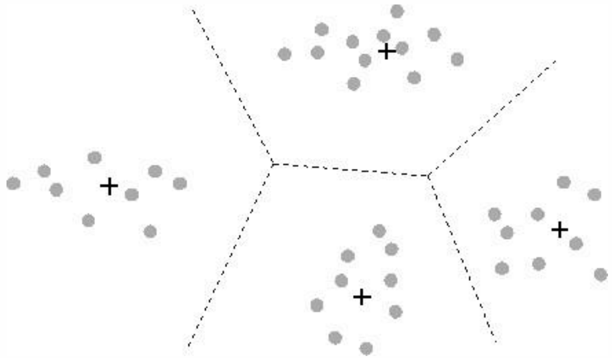

Гауссова смесь (Gaussian Mixture Model, GMM)

- Многомерное нормальное (гауссово) распределение:

$$\mathcal{N}(o;\mu,\Sigma) = \sqrt{(2\pi)^d|\det\Sigma|}\exp\left\{-\frac{1}{2}(o-\mu)^T\Sigma^{-1}(o-\mu)\right\}$$

- Гауссова смесь:

$$b_j(o_t) = \sum_{k=1}^{M} w_{jk}\mathcal{N}(o_t;\mu_{jk},\Sigma_{jk}), \qquad \text{где} \qquad w_{jk} \geq 0, \qquad \sum_{k=1}^{M} w_{jk} = 1.$$

- GMM – генеративная модель. Генерировать данные из нее очень просто:
  - Сначала генерируется номер компонента в соответствии с распределением $\{w_{jk}\}$
  - После этого генерируется вектор из распределения $\mathcal{N}(o_t;\mu_{jk},\Sigma_{jk})$
- С помощью GMM с достаточно большим числом компонентов можно приблизить любое непрерывное распределение с достаточной точностью

Гауссова смесь (Gaussian Mixture Model, GMM)

- Пусть имеется набор данных o_t. Как описать его распределение гауссовой смесью?

$$p(o_t) = \sum_{k=1}^{M} w_k \mathcal{N}(o_t; \mu_k, \Sigma_k)$$

- Для обучения используется метод максимального правдоподобия
- Задача не решается в явном виде, применяется итерационный EM-алгоритм.
- На E-шаге вычисляются апостериорные вероятности компонентов:

$$\gamma_{kt} = p(k|o_t) = \frac{w_k \mathcal{N}(o_t; \mu_k, \Sigma_k)}{\sum_{k=1}^{M} w_k \mathcal{N}(o_t; \mu_k, \Sigma_k)}$$

- На M-шаге вычисляются обновленные значения параметров:

$$\widehat{w}_k = \frac{1}{T} \sum_{t=1}^{T} \gamma_{kt}, \qquad \hat{\mu}_k = \frac{\sum_{t=1}^{T} \gamma_{kt} o_t}{\sum_{t=1}^{T} \gamma_{kt}}, \qquad \hat{\Sigma}_k = \frac{\sum_{t=1}^{T} \gamma_{kt} (o_t - \hat{\mu}_k)(o_t - \hat{\mu}_k)^T}{\sum_{t=1}^{T} \gamma_{kt}}$$

Гауссова смесь (Gaussian Mixture Model, GMM)

- Иллюстрация работы EM-алгоритма

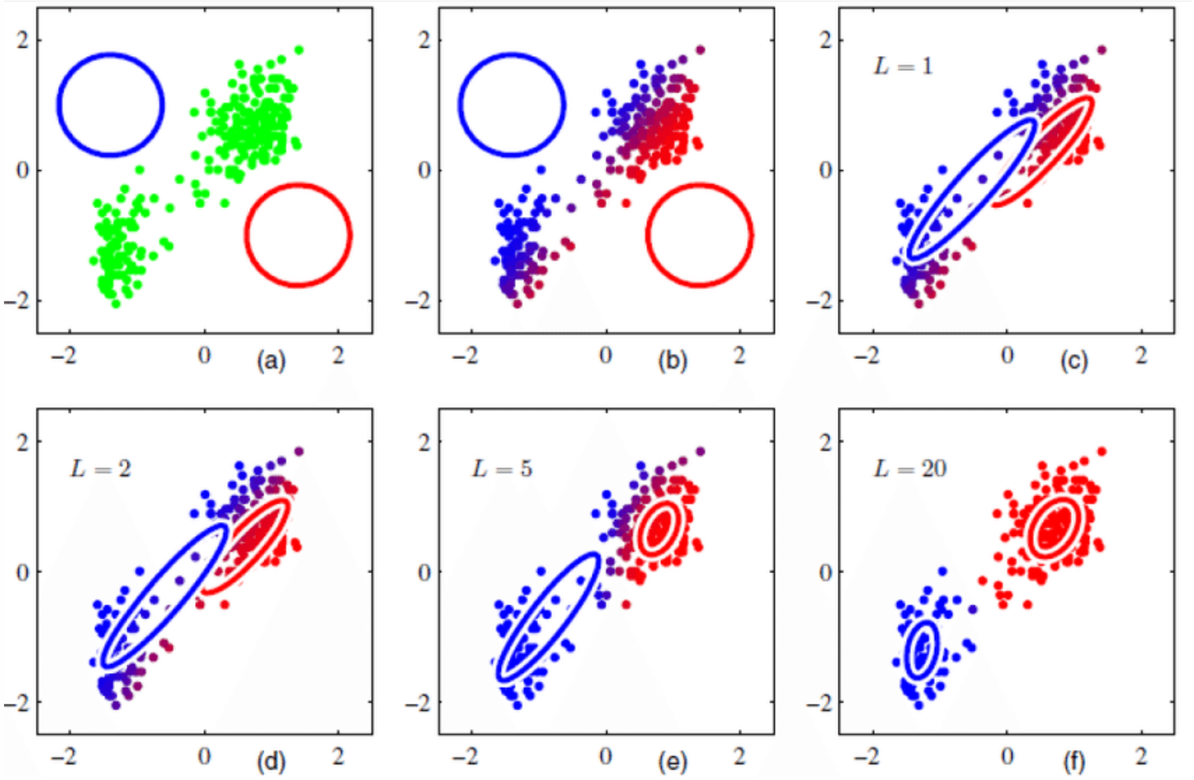

Гауссова смесь (Gaussian Mixture Model, GMM)

Полноковариационные vs. диагональные GMM

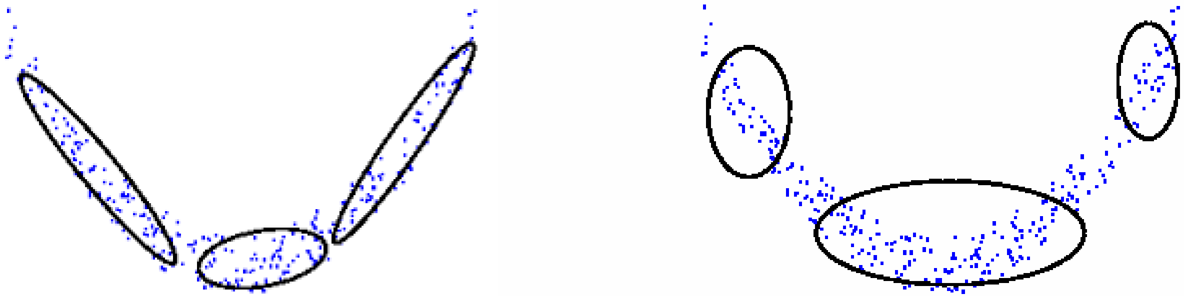

- GMM с полноковариационными матрицами – очень много параметров.
- GMM с диагональными матрицами – требуется больше компонент для аппроксимации
- Выход: декорреляция признаков
  - Использование MFCC (приближенно декоррелированы благодаря DCT)
  - Использование PCA (Principal Component Analysis), оно же KLT (Karhunen-Loeve Transform) или выбеливание (whitening)

Алгоритм Баума-Уэлша для обучения GMM-HMM

- Е-шаг точно такой же, как для дискретных распределений в состояниях
- На М-шаге начальные вероятности и матрица переходов обновляются так же
- Для обновления параметров GMM можно вывести следующие соотношения:

$$\hat{w}_{jk} = \frac{\sum_t \gamma_{jk}(t)}{\sum_t \gamma_j(t)}, \qquad \hat{\mu}_{jk} = \frac{\sum_t \gamma_{jk}(t) o_t}{\sum_t \gamma_{jk}(t)}, \qquad \hat{\Sigma}_{jk} = \frac{\sum_t \gamma_{jk}(t)(o_t - \hat{\mu}_{jk})(o_t - \hat{\mu}_{jk})^T}{\sum_t \gamma_{jk}(t)}$$

где

$$\gamma_{jk}(t) = \gamma_j(t) \frac{w_{jk} \mathcal{N}(o_t; \mu_{jk}, \Sigma_{jk})}{b_j(o_t)}$$

называются вероятностями «посещения» k-го компонента смеси (gaussian occupancy probabilities) в состоянии j в момент времени t.

Скрытые Марковские модели с GMM в состояниях (GMM-HMM)

Достоинства и недостатки GMM-HMM

+ Возможность описывать практически любые распределения в состояниях
+ Эффективная процедура обучения
- Динамика ограничена марковским свойством
- Вероятности переходов не зависят от времени
- HMM предполагает, что наблюдения на соседних кадрах независимы и зависят только от состояния, в котором находится модель (frame independence assumption)
- GMM является «локальной» моделью и учится по ML-критерию
- Для повышения точности надо увеличивать количество компонент GMM, число параметров растет, модель переобучается, расчеты замедляются.

Скрытые Марковские модели с GMM в состояниях (GMM-HMM)

Независимость наблюдений – как «обойти» ?

- Использование дельта-признаков:
  - Пусть имеется последовательность векторов $O = (o_1, o_2, \dots, o_T)$
  - Дополним векторы наблюдений «производными»:

$$\Delta o_t = (o_{t+1} - o_{t-1})/2 \approx \partial o_t / \partial t$$

$$\Delta\Delta o_t = o_{t+1} - 2o_t + o_{t-1} \approx \partial^2 o_t / \partial^2 t$$

- Frame stacking (splicing): объединение векторов признаков вокруг текущего в один длинный «супервектор»:

$$O_t = [o_{t-l}^T, \dots, o_{t-1}^T, o_t^T, o_{t+1}^T, \dots, o_{t+r}^T]^T$$

Скрытые Марковские модели с GMM в состояниях (GMM-HMM)

Генеративность и локальность GMM:

- Локальность: пространство оказывается разделено на «области» в каждой из которых ДОМИНИРУЕТ только один компонент GMM, а остальные не оказывают существенного влияния на значения правдоподобия.
- Генеративность: параметры генеративных моделей, как правило, выбираются согласно критерию максимального правдоподобия. Т.е. так, чтобы максимизировать правдоподобие ВЕРНОЙ гипотезы. Но если «конкурирующие» гипотезы близко, то качество распознавания будет низким.
- Дискриминативное обучение: идея – максимально отделить правильную гипотезу от всех конкурирующих. Подробнее – в конце лекции.

Скрытые Марковские модели с GMM в состояниях (GMM-HMM)

Переобучение и усложнение GMM – как бороться?

- Связывание параметров (не только состояний, но и параметров GMM, отдельных гауссиан, весов, вероятностей переходов)
- Векторное квантование признаков и использование дискретных распределений
- Создание большого пула гауссиан и «набор» отдельных GMM в состояниях из этого пула с различными весами. На этой идее основаны SGMM (subspace GMM)

- Общий вывод: GMM – не самый лучший из возможных классификаторов в состояниях HMM.

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

Распознавание с помощью суб-словных моделей

- Пусть требуется распознавать всевозможные последовательности из слов «мама», «мыла», «раму», «посуду». Строим из этих слов фонемный граф:

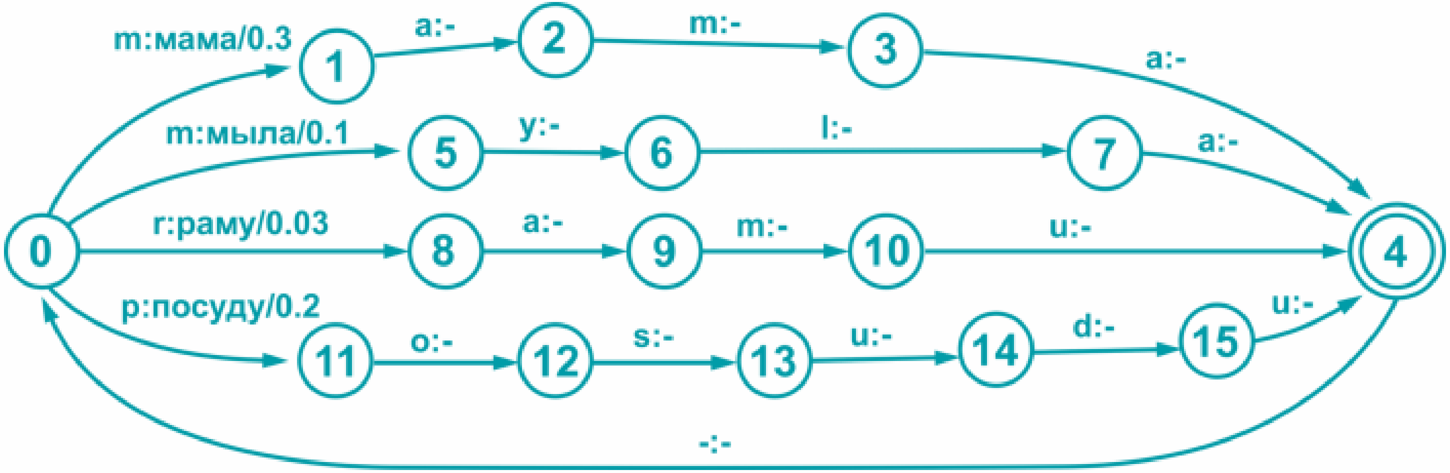

- Этот граф можно преобразовать в трифонный и, далее, в «стейтовый»
- На стейтовом графе можно искать лучший (Витерби) путь как в одной большой HMM. Это можно делать с помощью token-passing алгоритма!

Распознавание с помощью суб-словных моделей

- Гипотеза – тот же токен из token-passing алгоритма. Хранит в себе пройденный путь (чтобы можно было восстановить последовательность слов) и накопленный логарифм правдоподобия
- На каждом новом кадре
  - Вычисляются вероятности всех состояний всех HMM
  - Все активные гипотезы расширяются с учетом возможных переходов из состояния, правдоподобий в состояниях и вероятностей переходов
  - В каждом состоянии запоминается только лучшая гипотеза (Витерби)
- Если граф большой, то число активных гипотез растет очень быстро. Выход – отсекать (prune) «малоперспективные» гипотезы (beam pruning, histogram pruning,...)

Декодирование с языковой моделью

- Простейший сценарий:
  - В гипотезах (токенах) хранится пройденный путь.
  - Как только дошли до конца очередного слова запрашиваем у ЯМ его вероятность при данной истории и добавляем ее логарифм в score гипотезы
- Недостатки простейшего сценария:
  - Вероятность гипотезы меняется «скачкообразно»
  - Гипотеза может «выпасть» из beam’a до того, как ее score улучшится благодаря ЯМ
  - Частые обращения к ЯМ, дублирование запросов на похожих гипотезах
- Возможные решения:
  - «Внедрить» языковые вероятности непосредственно в стейтовый граф
  - «Размазать» их по длине слова

Построение графа распознавания

- Что надо иметь для построения стейтового графа:
  - Языковая модель или грамматика – показывает возможные переходы из слова в слово (с их вероятностями)
  - Лексикон (словарь транскрипций) – показывает, как произносятся слова, т.е. из каких фонем оно состоит. Может быть несколько транскрипций на слово, причем с разными вероятностями
  - Контекстная информация – какие трифоны получаются из фонем с учетом левого/правого контекстов и связывания состояний
  - Акустическая модель (HMM) – показывает из каких состояний состоит каждый трифон и задает вероятности переходов из состояния в состояние
- К счастью, каждый из этих видов информации можно представить в едином формате – Weighted Finite-State Transducer (WFST). WSFT является вероятностным конечным автоматом, трансформирующим входную последовательность символов в выходную.

Взвешенные конечные преобразователи (WFST)

- Конечный автомат (Finite State Machine, FSM): система, которая может находиться в конечном числе состояний и переходить из одного в другое при получении тех или иных входных данных:
  - Множество состояний Q, в нем выделяются начальные состояния $I \subset Q$ и конечные состояния $F \subset Q$;
  - Входной алфавит Σ, последовательность элементов которого поступает на вход;
  - Выходной алфавит
  - Функция перехода $\delta(q, a)$ определяет куда перейдет система, находящаяся в состоянии $q \in Q$, получив на вход токен $a \in \Sigma$ (либо специальный «пустой» символ ε)
  - В начале работы система находится в одном из состояний $q_0 \in I$.
  - На каждом шаге система считывает один токен $a \in \Sigma$ и делает переход согласно функции $\delta(q, a)$
  - Если по окончании входной последовательности система находится в состоянии $q \in \mathrm{F}$, то говорят, что система принимает данную последовательность.
- Конечный автомат, направленный лишь на определение того, принимается ли данная последовательность, называются акцепторами (Finite State Acceptors, FSA)

Взвешенные конечные преобразователи (WFST)

- Конечный преобразователь (Finite State Transducer, FST): аналог FSM, который не просто принимает входную последовательность, но и генерирует выходную.
  - На каждом шаге система считывает один токен $a \in \Sigma \cup \{\varepsilon\}$ и не только делает переход согласно функции $\delta(q, a)$, но и выдает выходной токен $b \in \Gamma \cup \{\varepsilon\}$, где Γ – выходной алфавит
  - FST удобно представлять в виде ориентированного графа, в котором узлы соответствуют состояниям, а на ребрах которого заданы пары из входного и выходного токенов $a{:}\,b$.
  - Говорят, что преобразователь T преобразует последовательность x в последовательность y (обозначение $x[T]y$) если существует путь по этому графу из какого-то начального состояния в какое-то конечное, на котором последовательность входных токенов равна x, а последовательность выходных токенов равна y.
- Операции над FST:
  - Объединение $T \cup S$: объединяются множества путей в двух графах
  - Конкатенация $T \cdot S$: все пути второго графа приклеиваются к путям первого
  - Композиция $T \circ S$: $x[T \circ S]y$ тогда и только тогда, когда существует такая последовательность z, что $x[T]z$ и $z[S]y$. Т.е. композиция как бы последовательно применяет преобразования сначала от T, а потом от S.

Взвешенные конечные преобразователи (WFST)

- Взвешенный конечный преобразователь (Weighted Finite State Transducer, WFST): каждому ребру, а также начальным и конечным узлам графа сопоставлен ВЕС
  - Все веса берутся из некоторого полукольца $\mathbb{K}$, т.е. их можно «складывать» $\oplus$ и «умножать» $\otimes$
  - Вес пути π, состоящего из ребер $e_1, e_2, \dots, e_k$, равен «произведению» весов ребер: $w[\pi] = w[e_1] \otimes \cdots \otimes w[e_k]$
  - Пусть $P(x, y)$ – множество путей π, из какого-то начального узла в какой-то конечный узел с входной последовательностью x и выходной последовательностью y, а $i(\pi)$ и $f(\pi)$ – это начальный и конечный узлы пути π.
  - Тогда вес преобразования $x[T]y$ определяется как «сумма» по всем путям из $P(x, y)$:

$$[\![T]\!](x, y) = \bigoplus_{\pi \in P(x,y)} w[i(\pi)] \otimes w[\pi] w[f(\pi)].$$

  - Если веса – это вероятности, то $[\![T]\!](x, y)$ – суммарная вероятность всех путей из $P(x, y)$. В этом случае $\mathbb{K}$ – вероятностное полукольцо, а $\oplus$ и $\otimes$ - обычные арифметические сложение и умножение
  - Если веса – это логарифмы вероятностей, то $\mathbb{K}$ – логарифмическое полукольцо: в этом случае $a \otimes b = a + b$ и $a \oplus b = \log\left(e^a + e^b\right)$
  - Различные пути можно сравнивать по их весу и выбирать **оптимальный**

Построение WFST-графа распознавания

- Традиционно, WFST для отдельных компонентов обозначают так:
  - G – для грамматики или n-граммной ЯМ (переводит слова в предложение)
  - L – для лексикона (переводит фонемы в слова)
  - C – для контекстной зависимости (переводит трифоны в фонемы)
  - H – для HMM (переводит состояния трифонов в сами трифоны)
- С помощью композиции этих WFST можно построить преобразователь, который транслирует последовательность состояния фонем прямо в предложение!

$$W = H \circ C \circ L \circ G$$

- Такой WFST фактически определяет граф распознавания для декодера.
- В ходе построения граф дополнительно оптимизируют с помощью операций минимизации и детерминизации, а также «проталкивают» веса ближе к началу
- OpenFST – open-source библиотека для работы с WFST

Построение WFST-графа распознавания

- На рисунке показан пример композиции $L \circ G$, где L соответствует лексикону из 4 слов («мама», «мыла», «раму», посуду»), а G – униграммной ЯМ с вероятностями 0.3, 0.1, 0.03, 0.2 для этих слов.

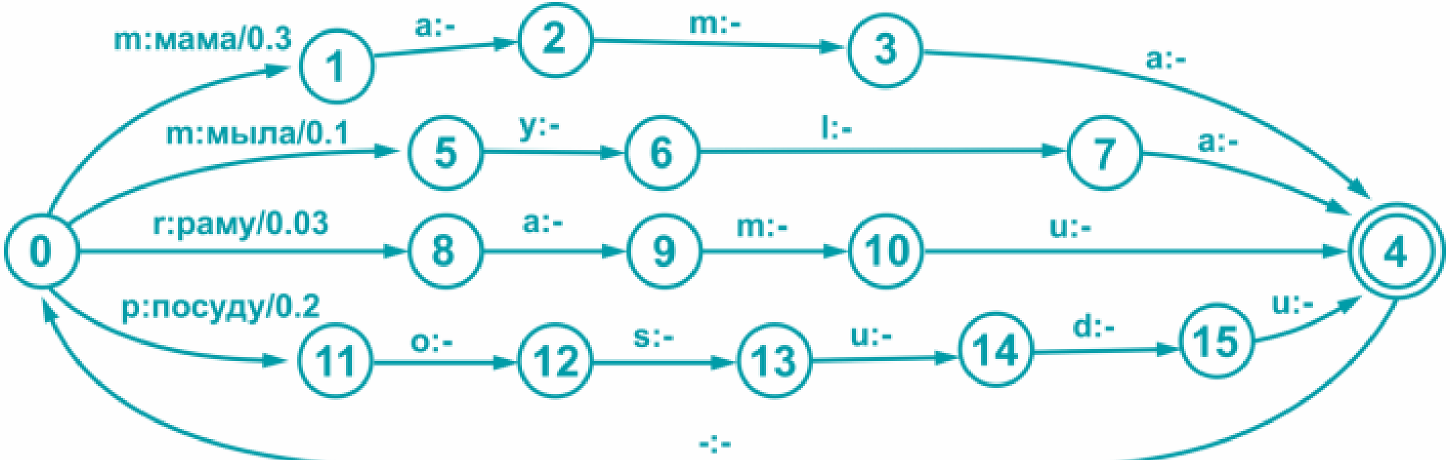

- Подавая ему на вход последовательность фонем, соответствующих произнесенным словам, на выходе мы получим последовательность слов.

Базовые параметры декодера

- Для настройки функционирования системы ASR есть ряд параметров:
  - Ширина луча поиска, beam width (для beam pruning)
  - Максимально допустимое количество гипотез (токенов), maximum hypotheses number (для histogram pruning)
  - Штраф за вход в слово α (word insertion penalty). Заставляет декодер предпочитать более длинные слова коротким.
  - Вес языковой модели β (lm scale).
- С учетом α и β декодер ищет последовательность слов W, которая максимизирует следующую величину:

$$\arg\max_W [\log p(O|W) + \alpha|W| + \beta \log P(W)] = \arg\max_W p(O|W)|W|^{\alpha} P(W)^{\beta}$$

- С помощью настройки этих параметров можно регулировать соотношение между точностью и скоростью работы системы распознавания

N-best списки и словные сети. Рескоринг

- Иногда требуется вернуть не только лучшую гипотезу, а N лучших.
- Для этого в состояниях надо хранить не по одному, а по несколько лучших токенов!
- Список лучших гипотез называют N-best list.
- Более компактное представление набора лучших гипотез – словная сеть (word lattice):

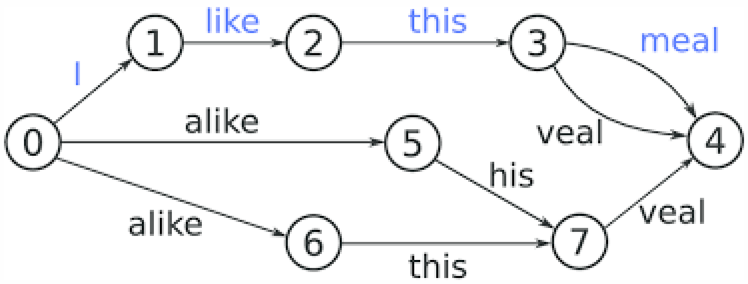

- Часто правильная гипотеза – не лучшая в списке/сети из-за «слабой» языковой модели
- В этом случае можно применить рескоринг (re-scoring): пересчитать веса гипотез с помощью продвинутой ЯМ (n-граммной с увеличенным n, нейронной)

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

Про дискриминативное обучение GMM-HMM

- Традиционный метод обучения GMM-HMM – метод максимального правдоподобия:

$$\hat{\lambda} = \underset{\lambda}{\operatorname{argmax}} P(O|W,\lambda)$$

- НО: он «тянет вверх» правдоподобие ТОЛЬКО на истинных последовательностях слов!
- При этом правдоподобие «альтернативных» гипотез может быть очень близко
- Дискриминативные критерии стремятся максимально отделить (discriminate) истинную гипотезу от всех остальных.
- Максимум взаимной информации (MMI):

$$\hat{\lambda} = \underset{\lambda}{\operatorname{argmax}} P(W|O,\lambda) = \underset{\lambda}{\operatorname{argmax}} \frac{P(O|W,\lambda)P(W)}{\sum_{W'} P(O|W',\lambda)P(W')}$$

- Суммирование в знаменателе проводится по всем альтернативным гипотезам (lattice!)
- Обучение: расширенный алгоритм Баума-Уэлша (extended BW, EBW).
- Другие критерии: Minimum Word/Phone Error (MWE/MPE), Boosted MMI (BMMI)

Расширенный алгоритм Баума-Уэлша

- Базовый алгоритм Баума-Уэлша:

$$\hat{\mu}_{jk} = \frac{\sum_t \gamma_{jk}(t) o_t}{\sum_t \gamma_{jk}(t)}, \qquad \hat{\Sigma}_{jk} = \frac{\sum_t \gamma_{jk}(t)(o_t - \hat{\mu}_{jk})(o_t - \hat{\mu}_{jk})^T}{\sum_t \gamma_{jk}(t)}$$

- Для всех дискриминативных критериев EBW имеет одинаковую форму

$$\hat{\mu}_{jk} = \frac{\sum_t \left(\gamma_{jk}^{NUM}(t) - \gamma_{jk}^{DEN}(t)\right) o_t}{\sum_t \left(\gamma_{jk}^{NUM}(t) - \gamma_{jk}^{DEN}(t)\right)}$$

$$\hat{\Sigma}_{jk} = \frac{\sum_t \left(\gamma_{jk}^{NUM}(t) - \gamma_{jk}^{DEN}(t)\right)(o_t - \hat{\mu}_{jk})(o_t - \hat{\mu}_{jk})^T}{\sum_t \left(\gamma_{jk}^{NUM}(t) - \gamma_{jk}^{DEN}(t)\right)}$$

- В них $\gamma_{jk}^{NUM}(t)$, $\gamma_{jk}^{DEN}(t)$ - вероятности «посещения» гауссовых компонент, вычисленные по сетям (lattice) числителя и знаменателя.
- Для разных критериев немного отличаются лишь алгоритмы оценки $\gamma_{jk}^{NUM}(t)$ и $\gamma_{jk}^{DEN}(t)$

План лекции

- Скрытые Марковские Модели и связанные с ними задачи
- Применение HMM для распознавания речи
- Гауссовы смеси, обучение GMM-HMM
- Взвешенные конечные преобразователи. WFST-декодер. Словные сети
- Дискриминативное обучение GMM-HMM
- Адаптация систем распознавания речи

Адаптация систем распознавания речи

- Современные системы, как правило, дикторонезависимые (Speaker Independent, SI)
- Система, настроенная на конкретный голос, – дикторозависимая (SD)
- Адаптация – способ улучшить распознавание конкретного голоса дикторонезависимой системой по небольшому набору данных для этого голоса
- Типы адаптации:
  - Контролируемая (supervised) – даны фонограммы голоса и их текстовые расшифровки
  - Неконтролируемая (unsupervised) – даны только фонограммы
  - Оффлайн – фонограммы записываются, все разом обрабатываются, на выходе адаптированная модель
  - Онлайн – постепенная адаптация по мере поступления данных целевого голоса
- Для пользователя удобнее всего неконтролируемая онлайн адаптация (от него вообще ничего не требуется). Но она наиболее сложна в реализации и работает не так хорошо
- Дикторо-адаптивное обучение (Speaker Adaptive Training, SAT): в ходе обучения применяется такая же «адаптация», как и при распознавании.

Нормализация длины голосового тракта

- В зависимости от длины голосового тракта меняется основной тон (ОТ) речи
- Чем выше основной тон, тем спектрограмма более «растянута» по частоте
- Идея для адаптации: растянуть/сжать все спектрограммы к ~одному значению ОТ до вычисления mel-fbanks
- Такой способ называется Vocal Tract Length Normalization (VTLN)
- На большей части частотного диапазона преобразование линейное
- Как искать коэффициент растяжения/сжатия?
- Перебор значений 0.9:0.02:1.1 и выбор того, на котором максимально правдоподобие SI-модели на адаптационных данных

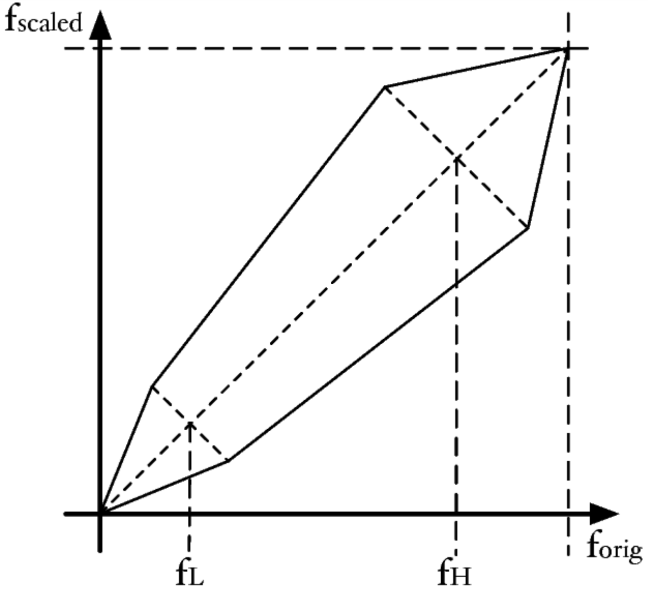

Maximum Likelihood Linear Regression (MLLR)

- Пусть имеется построенная GMM-HMM, ее правдоподобие максимально на обучающих данных. Но данные нового диктора распределены немного иначе…
- Идея: давайте для каждого компонента каждой GMM немного «подправим» средние векторы, чтобы максимизировать правдоподобие на новых данных
- Как подправим? Аффинным преобразованием: $\mu_{jk}^{new} = A_{jk}\mu_{jk} + b_{jk}$
- Решение итерационное, EM-алгоритм
- Можно адаптировать не только средние, но и ковариации
- Если гауссовых компонентов много, а данных мало – переобучение. Поэтому для «похожих» гауссиан ищут общее преобразование. Гауссианы «кластеризуют» с помощью дерева, чем больше данных, тем больше кластеров можно преобразовывать.
- MLLR хорошо работает даже на очень небольших объемах данных (десятки секунд)

Constrained MLLR (CMLLR) / feature-space MLLR (fMLLR)

- В MLLR мы двигали компоненты GMM к данным
- Но можно же и в обратную сторону!
- Идея: давайте найдем такое аффинное преобразование координат, чтобы максимизировать правдоподобие на преобразованных новых данных:

$$o_t^{new} = Ao_t + b$$

- Решение опять итерационное, EM-алгоритм
- Ищется только одна матрица и один вектор, значит шанс переобучиться минимален
- CMLLR/fMLLR хорошо подходит для дикторо-адаптивного обучения:
  - Обучим дикторонезависимую модель
  - Для каждого диктора из обучающей выборки найдем преобразование
  - Переучим модель на преобразованных данных
  - НО в test-time без преобразования уже ничего работать НЕ БУДЕТ!

Maximum A Posteriori (MAP): байесовская адаптация

- В MLLR/fMLLR мы максимизировали правдоподобие модели на адаптационных данных
- В методе MAP ищутся параметры модели, максимизирующие апостериорное распределение, полученное в результате «наблюдения» адаптационных данных:

$$\hat{\lambda} = \underset{\lambda}{\operatorname{argmax}}\, p\left(\lambda \middle| O^{adapt}\right) = \underset{\lambda}{\operatorname{argmax}}\, p\left(O^{adapt} \middle| \lambda\right) p(\lambda)$$

- По сравнению с ML добавилось априорное распределение $p(\lambda)$ – это просто SI-модель
- Если бы его не было, получилась бы стандартная оценка для среднего:

$$\mu_{jk}^{SD} = \frac{\sum_t \gamma_{jk}(t) o_t}{\sum_t \gamma_{jk}(t)} = \frac{\sum_t \gamma_{jk}(t) o_t}{c_{jk}}$$

- А получается так:

$$\hat{\mu}_{jk} = \frac{\tau_{jk}\mu_{jk}^{SI} + \sum_t \gamma_{jk}(t) o_t}{\tau_{jk} + \sum_t \gamma_{jk}(t)} = \frac{\tau_{jk}\mu_{jk}^{SI} + c_{jk}\mu_{jk}^{SD}}{\tau_{jk} + c_{jk}}$$

- Получается, что компоненты, которые не «посещались», не изменятся

Сравнение MLLR и MAP

- MLLR хорошо работает на очень малых объемах адаптационных данных
- MLLR легко адаптировать к различным объемам доступных данных
- MAP на малых объемах адаптационных данных адаптируется плохо
- Но с ростом объема MAP улучшается и в конце концов обгоняет MLLR
- В пределе MAP-решение стремится к ML-решению, т.е. к чистой SD-модели
- Существуют различные комбинации этих подходов, которые сочетают достоинства обоих

Литература к этой лекции

- L. R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. Proceedings of the IEEE, 77(2):257–286, 1989. – про HMM и основные задачи
- S. J. Young, J. J. Odell, and P. C. Woodland. Tree-based state tying for high accuracy acoustic modelling. In Proceedings of the Workshop on Human Language Technology, HLT'94, pages 307–312, 1994. – про деревья решений и связывание состояний
- Jeff A. Bilmes. A gentle tutorial of the em algorithm and its application to parameter estimation for gaussian mixture and hidden markov models. Technical Report ICSI-TR-97-021, University of Berkeley, 4(6), 2000. – про EM-алгоритм для GMM и GMM-HMM
- Mehryar Mohri.Weighted Finite-State Transducer Algorithms. An Overview, pages 551–563. Springer Berlin Heidelberg, 2004. – про WFST
- M. J. F. Gales. Maximum likelihood linear transformations for hmm-based speech recognition. Computer Speech & Language, 12(2):75–98, 1998. – про MLLR

Спасибо за внимание!

Вопросы?