академия больших данных

mail.ru group

Text to Speech

Калиновский И.А.
Just AI, к.т.н.

Синтез речи на основе DNN

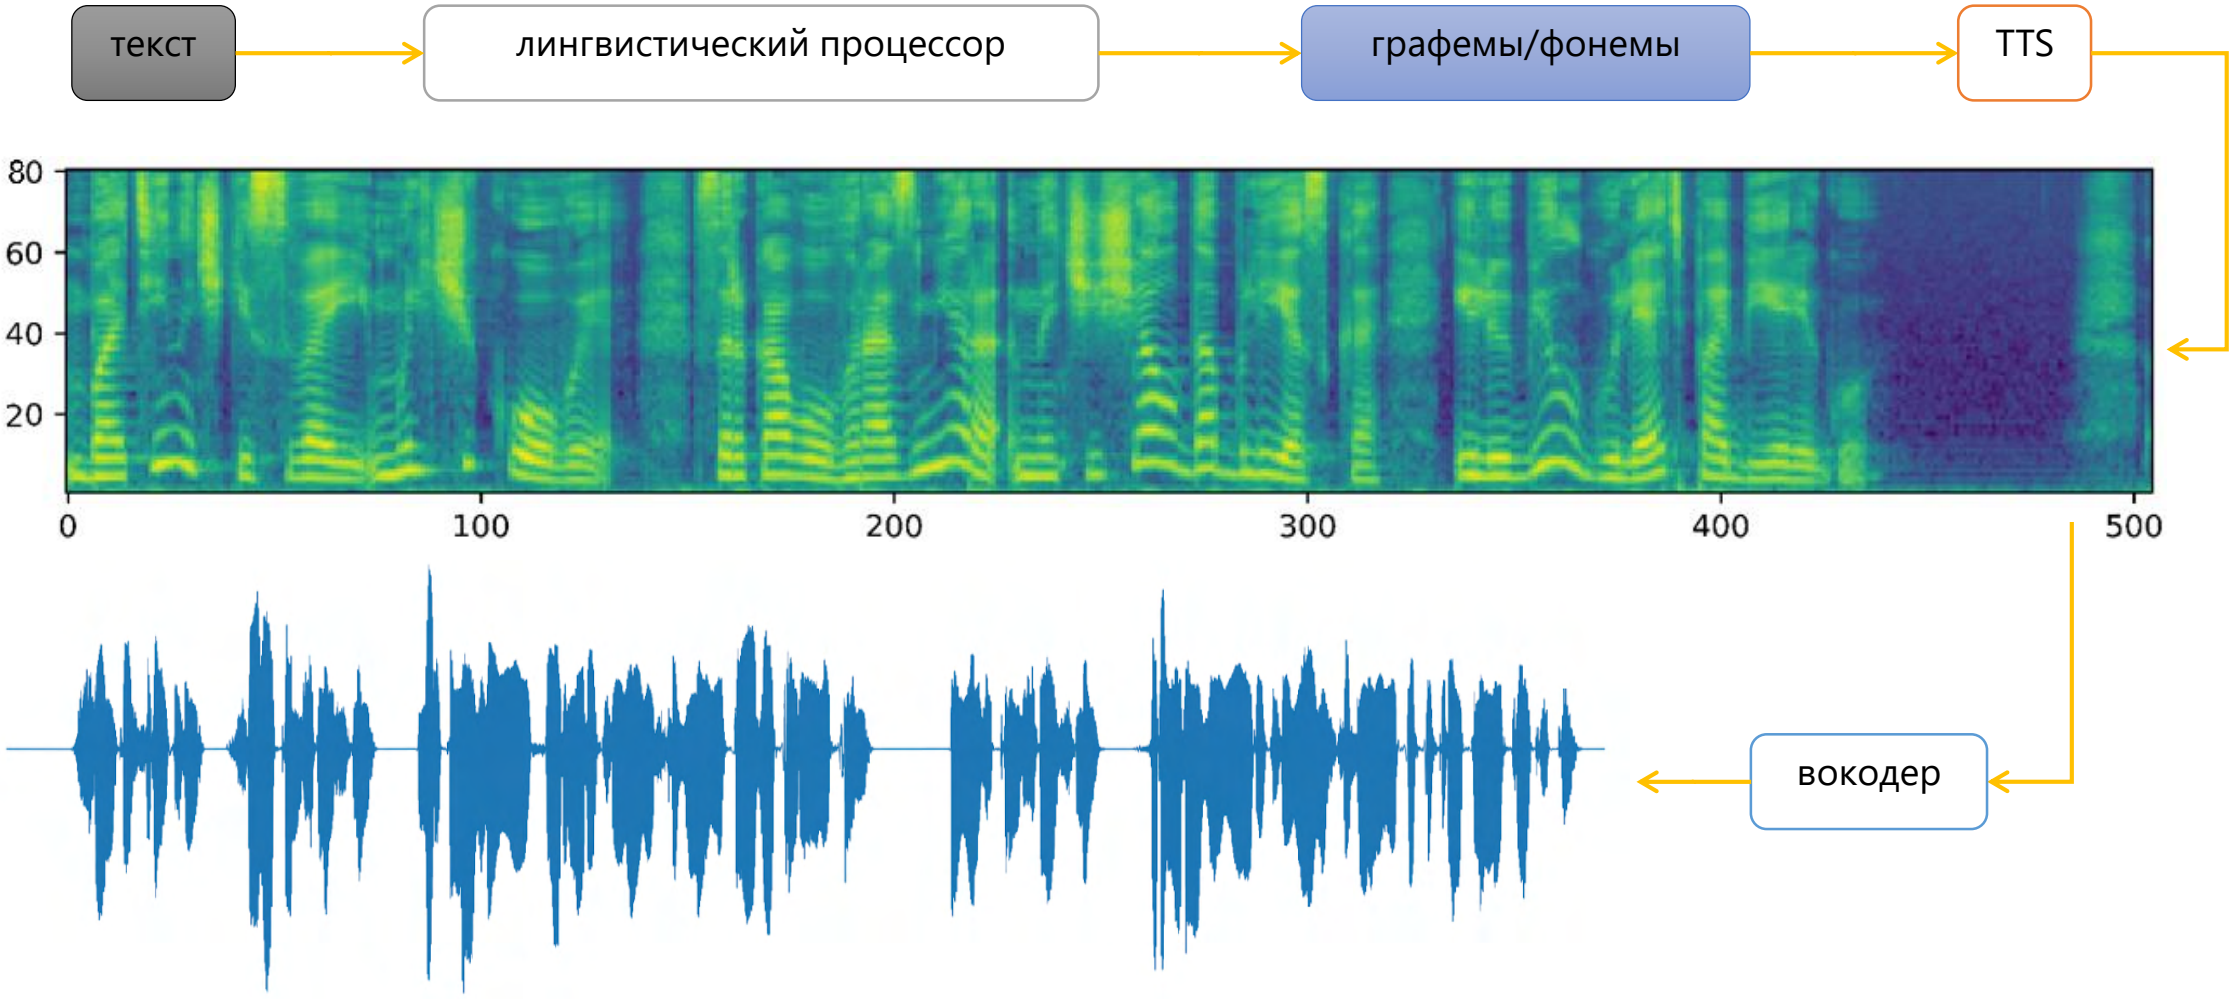

Фонетическое членение речи

Непрерывный поток звучащей речи является структурированным, он членится на разные по объему отрезки, фонетические единицы, которые образуют иерархическую систему.

Сегодня светит солнце, но дует ветер.

синтагмы	*сегодня светит солнце*	*но дует ветер*
слова	*сегодня* | *светит* | *солнце*	*но* | *дует* | *ветер*
слоги	*се-го-дня* | *све-тит* | *сол-нце*	*но* | *ду-ет* | *ве-тер*
фонемы	s‘/i_1-v/o_0-d‘/n‘/a_4 | s/v'/e_0-t'/i_4/t | s/o_0-n/c/y_4	*n*/o_1 | *d*/u_0-*j*/i_4/*t* | *v*'/e_0-*t*'/i_4/*r*

Лингвистический процессор

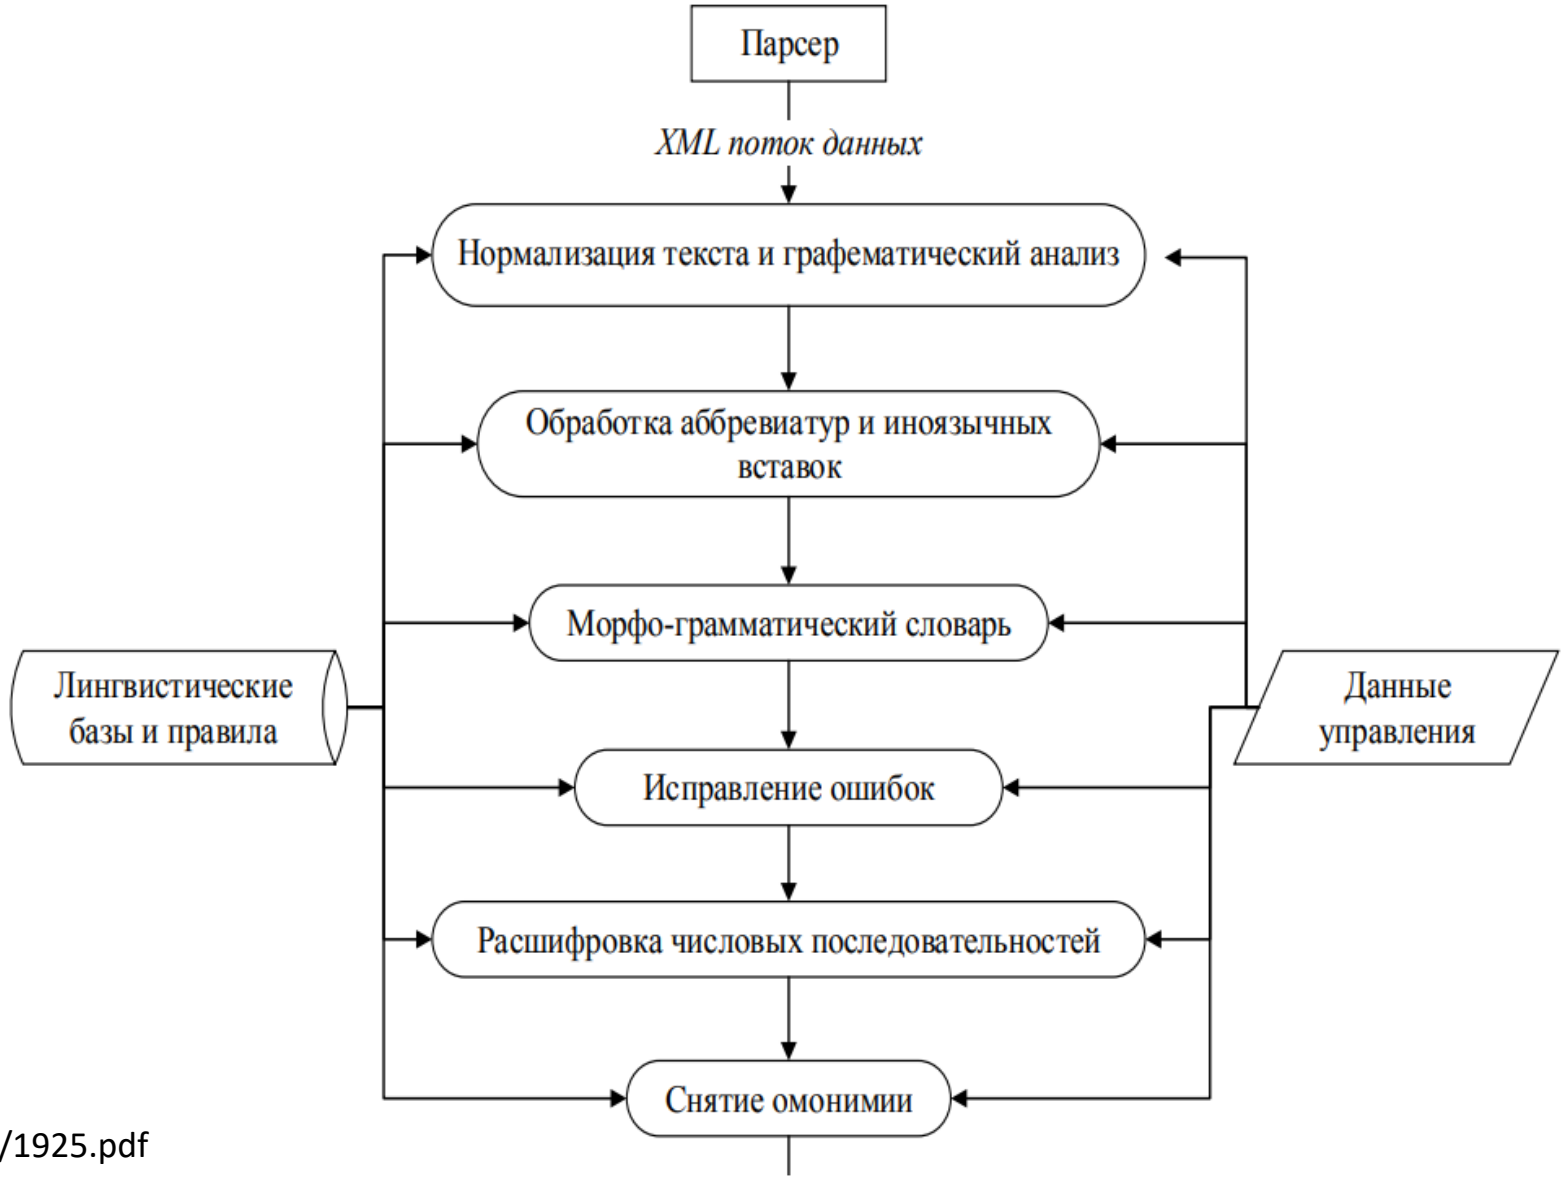

https://books.ifmo.ru/file/pdf/1925.pdf

Как собрать для русского языка?

Нормализовать текст: https://github.com/snakers4/russian_stt_text_normalization

Разбить на предложения: https://natasha.github.io/razdel

Построить транскрипцию: https://github.com/nsu-ai/russian_g2p

Спектр речевого сигнала

«Ботиночки свои мальчиковые, сорокового размера, начищал до блеска и любил гулять по берегу.»

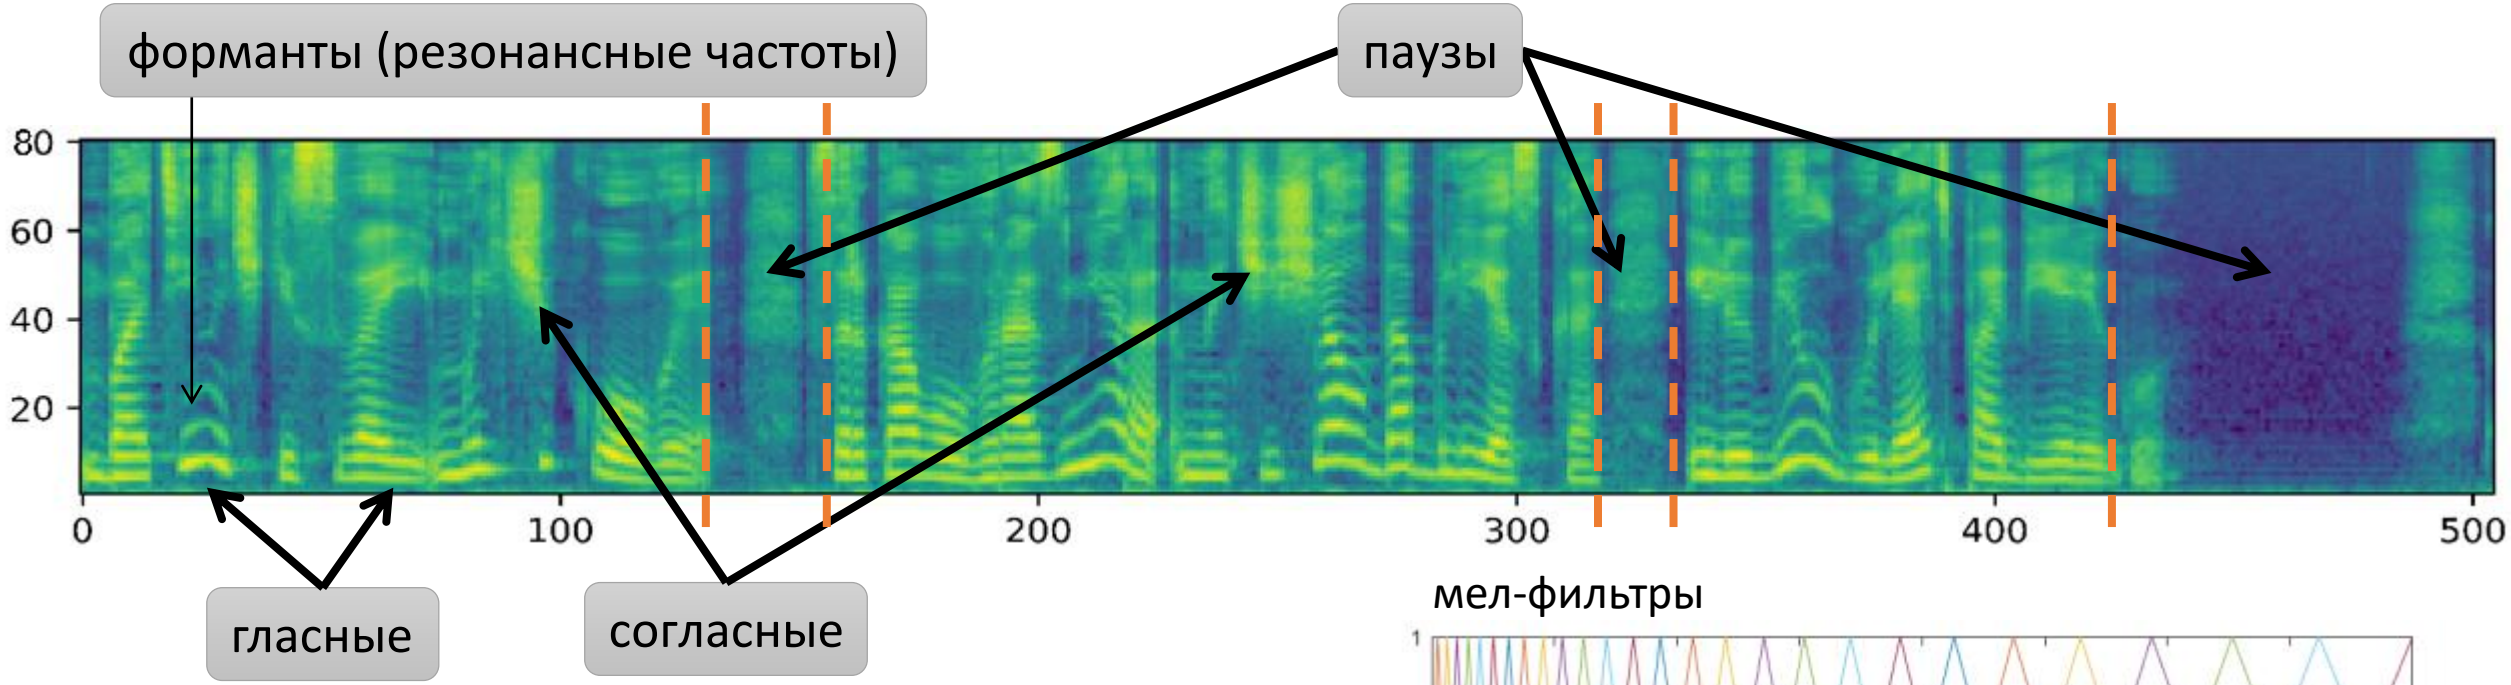

мел-фильтры

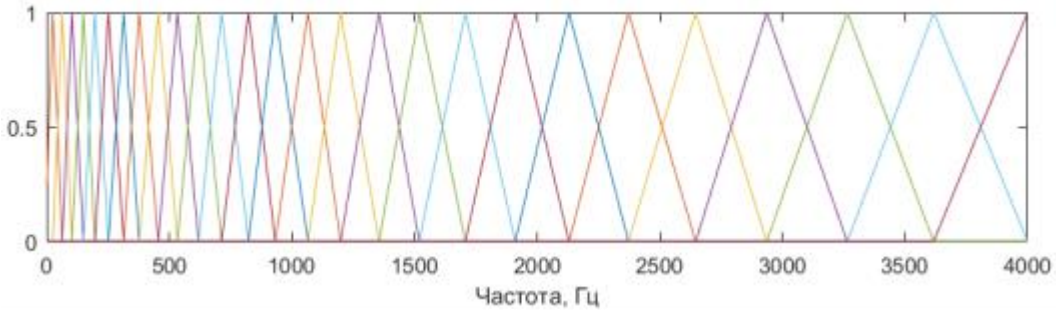

Как подготовить аудиофичи?

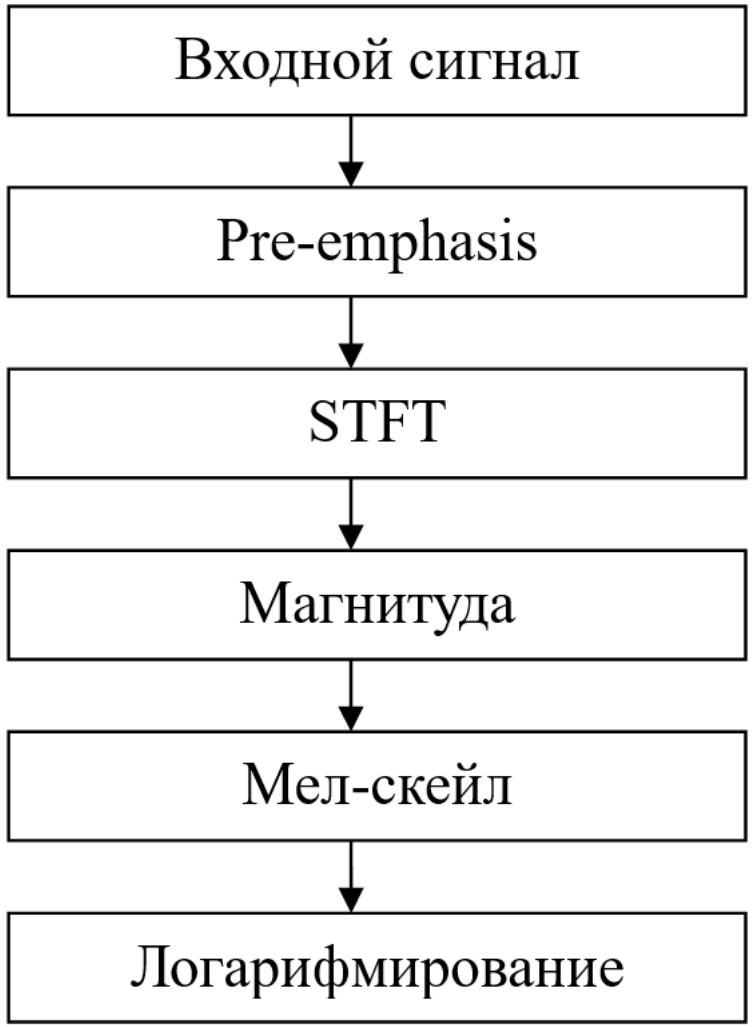

$y[n] = x[n] - 0{,}97 * x[n-1]$

Где взять датасет?

RUSLAN (22000 семплов, 44КГц, PCM16): https://ruslan-corpus.github.io

OPEN STT: https://github.com/snakers4/open_stt

Другие: https://github.com/coqui-ai/open-speech-corpora

Извлечь аудио с субтитрами из YouTube

Разметить аудиокниги

Записать в студии

Как оценивать качество?

С привлечением слушателей:

- MOS: https://en.wikipedia.org/wiki/Mean_opinion_score
- MUSHRA: https://en.wikipedia.org/wiki/MUSHRA

Автоматические методы:

- ASR
- PESQ: https://en.wikipedia.org/wiki/Perceptual_Evaluation_of_Speech_Quality
- Neural MOS prediction: https://arxiv.org/pdf/2007.08267.pdf

Классификация моделей

По архитектуре:

Авторегрессионные

- обучение и инференс
- только инференс

Параллельные

По типу блоков:

Рекурентные

Сверточные

Трансформеры

По типу входных фичей:

Текст

Лингвистические признаки

Мел-спектр

Длительности фонем

Пич (F_0)

Энергия

Tacotron2, 2018

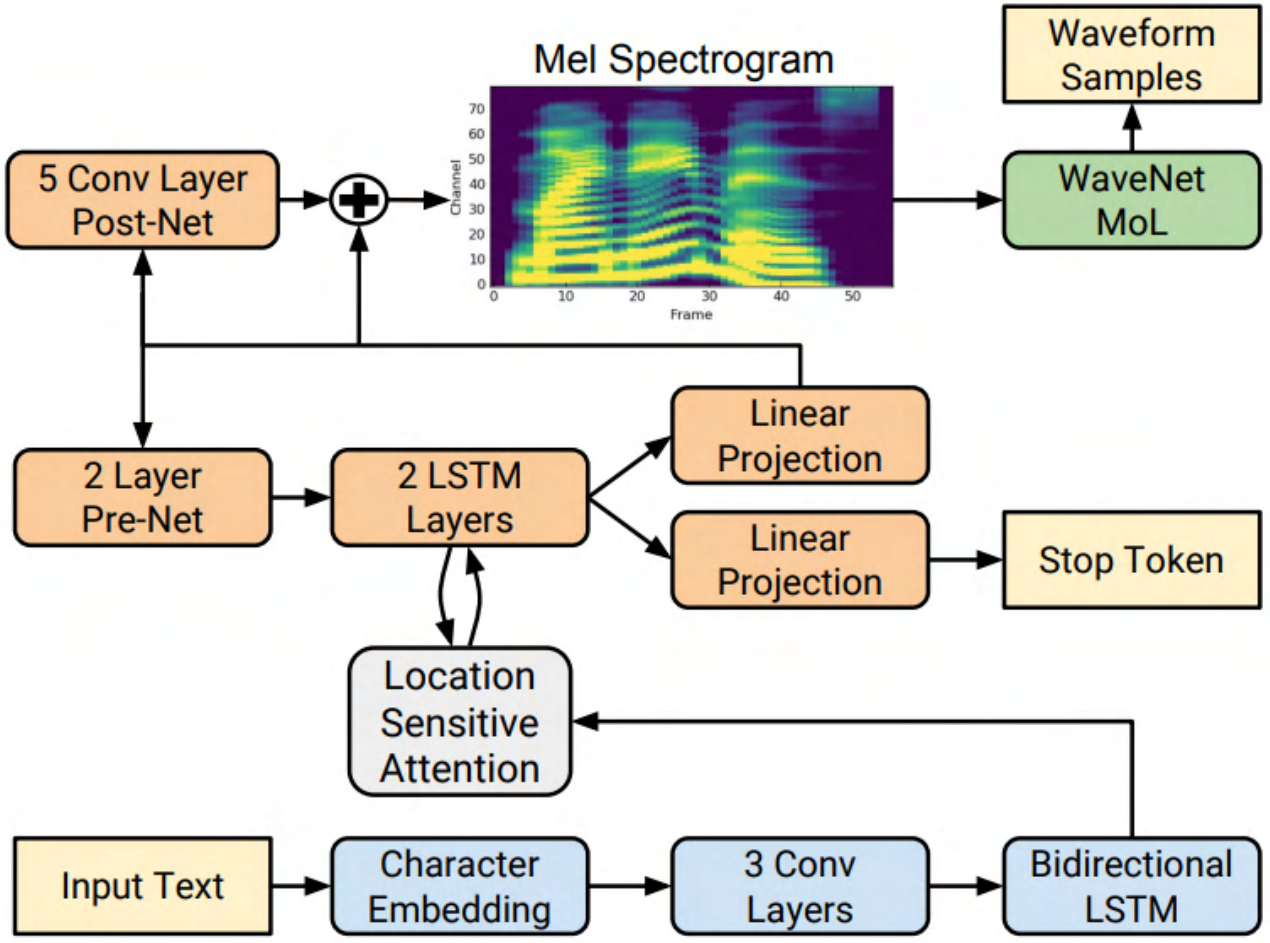

Location Sensitive Attention

$$e_{i,j} = w^T \tanh(W s_{i-1} + V h_j + b)$$

h – выходы текстового энкодера, *s* – состояние декодера

$$f_i = F * \alpha_{i-1}$$

α – распределение внимания на предыдущем шаге

$$e_{i,j} = w^T \tanh(W s_{i-1} + V h_j + U f_{i,j} + b)$$

Losses

L_1 или L_2 на спектр

BCE на Stop Token

Как быть, если нет вокодера под рукой?

Algorithm 1 Griffin–Lim phase reconstruction with $\mathbf{STFT}_{\alpha,\beta}$

Input: $|\mathbf{X}^{[0]}| \in \mathbb{R}^{\alpha N \times T}$, where T is total frame number

Output: $\hat{x}(t)$

initial random phase $\mathbf{\Phi} \in \mathbb{R}^{\alpha N \times T}$

$\mathbf{X}^{[1]} = |\mathbf{X}^{[0]}| \odot \mathbf{\Phi}$

$x^{[1]}(t) = \mathbf{iSTFT}_{\alpha,\beta}\left[\mathbf{X}^{[1]}\right]$

for $i = 1 : I - 1$ **do**

$\mathbf{Y}^{[i]} = \mathbf{STFT}_{\alpha,\beta}\left[x^{[i]}(t)\right]$

$\mathbf{X}^{[i+1]} = |\mathbf{X}^{[0]}| \odot \exp\left\{j\angle\mathbf{Y}^{[i]}\right\}$

$x^{[i+1]}(t) = \mathbf{iSTFT}_{\alpha,\beta}\left[\mathbf{X}^{[i+1]}\right]$

end for

return $\hat{x}(t) = x^{[I]}(t)$

Tacotron2, 2018

Достоинства:

- Высокое качество речи
- Проверена работоспособность для множества языков
- Возможен синтез в реальном времени на CPU, в т.ч. в режиме стриминга

Недостатки:

- Нестабильный синтез (пропуск слов, безостановочная генерация)
- Деградация качества при увеличении длины высказывания
- Слабые возможности по управлению речью
- Медленная сходимость
- Медленное обучение и инференс (на GPU)

Как улучшить стабильность?

Удалить длинные паузы

Добавить пунктуацию как дополнительный вход в модель

Использовать монотонное внимание:

- Forward Attention: https://arxiv.org/pdf/1807.06736.pdf
- Monotonic Chunkwise Attention: https://arxiv.org/pdf/1712.05382.pdf
- Location-Relative Attention: https://arxiv.org/pdf/1910.10288.pdf

CTC-loss

Forward Attention

Algorithm 1 Forward Attention

Initialize:

$\hat{\alpha}_0(1) \leftarrow 1$

$\hat{\alpha}_0(n) \leftarrow 0, n = 2, ..., N$

for $t = 1$ to T **do**

$y_t(n) \leftarrow Attend(\boldsymbol{x}, \boldsymbol{q}_t)$

$\hat{\alpha}'_t(n) \leftarrow (\hat{\alpha}_{t-1}(n) + \hat{\alpha}_{t-1}(n-1))y_t(n)$

$\hat{\alpha}_t(n) \leftarrow \hat{\alpha}'_t(n) \Big/ \sum_{m=1}^{N} \hat{\alpha}'_t(m)$

$\boldsymbol{c}_t \leftarrow \sum_{n=1}^{N} \hat{\alpha}_t(n)\boldsymbol{x}_n$

end for

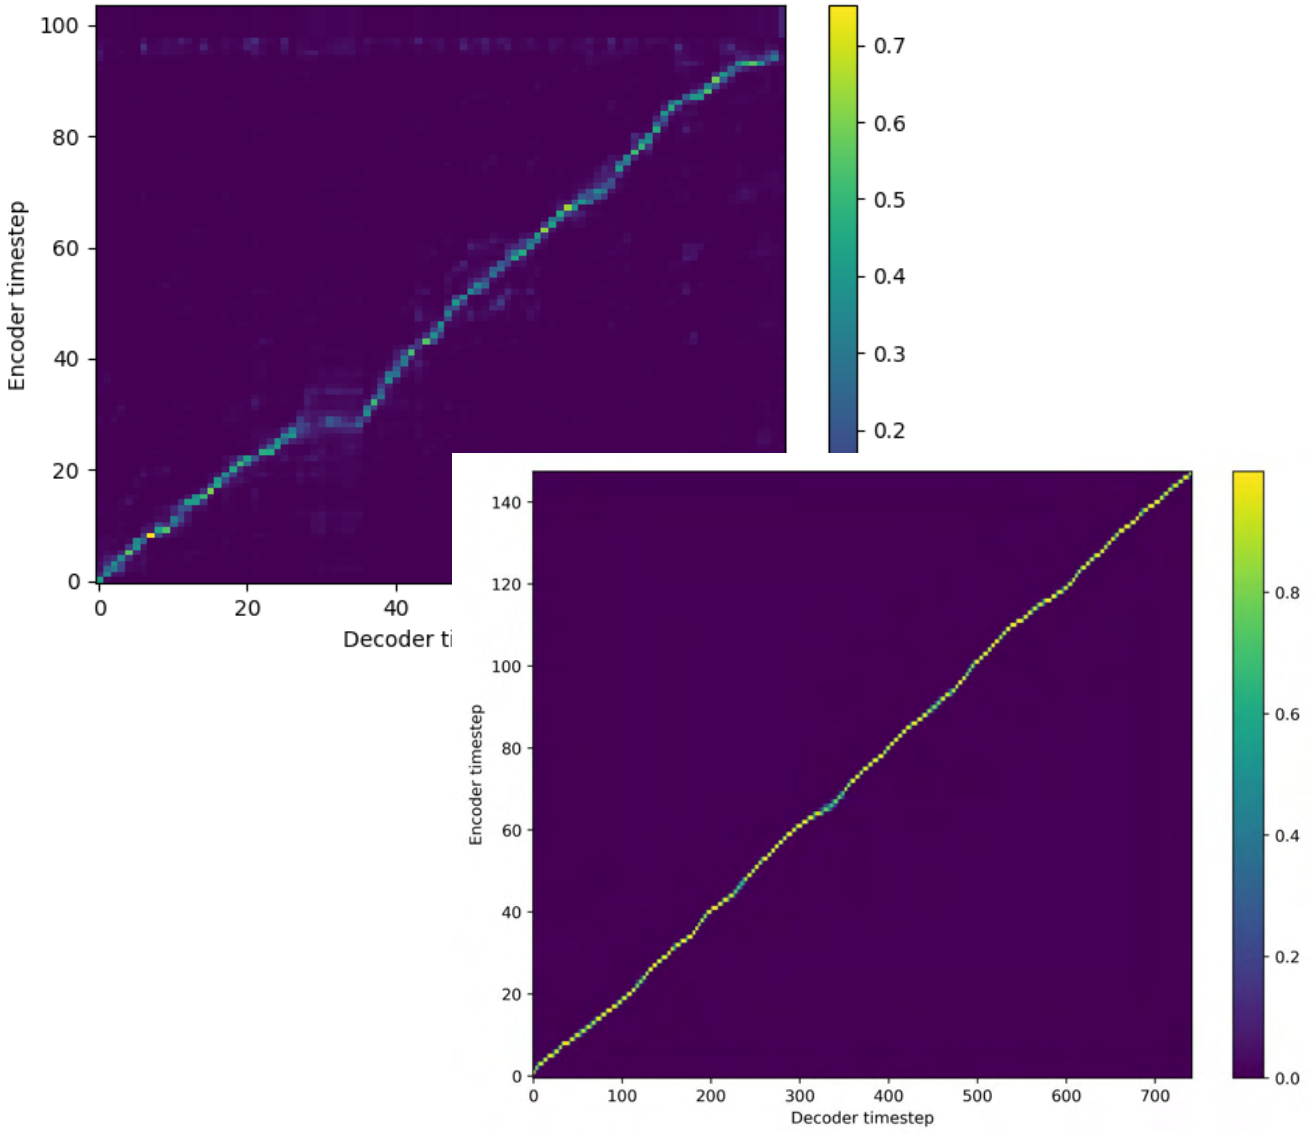

Как ускорить сходимость?

Семплировать в батч спектры равной длины

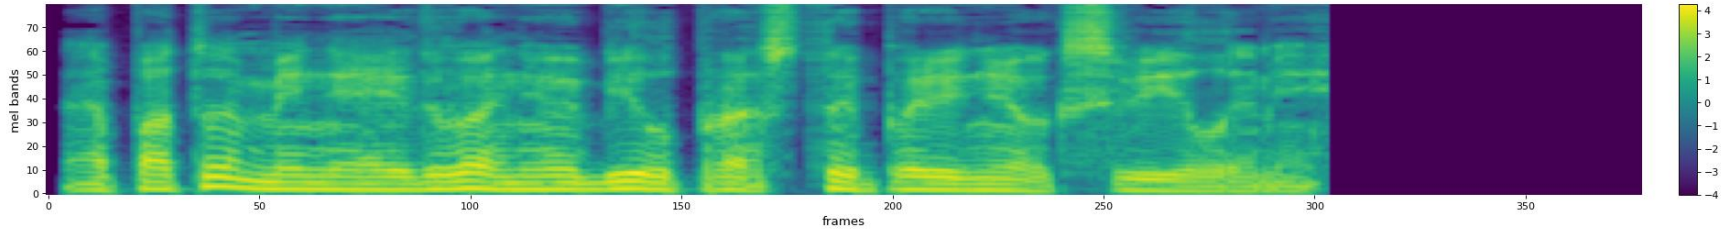

Применять Guided Attention Loss (https://arxiv.org/pdf/1710.08969.pdf)

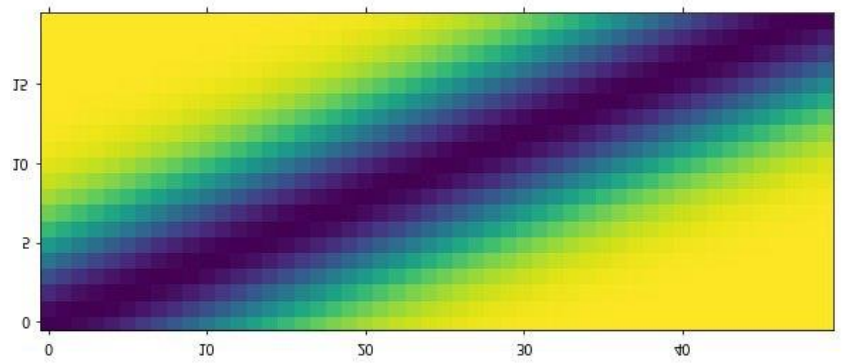

Заполнять паузы несколькими символами

Как ускорить обучение?

Увеличить hop

Предсказывать несколько фреймов за шаг

FastSpeech, 2019

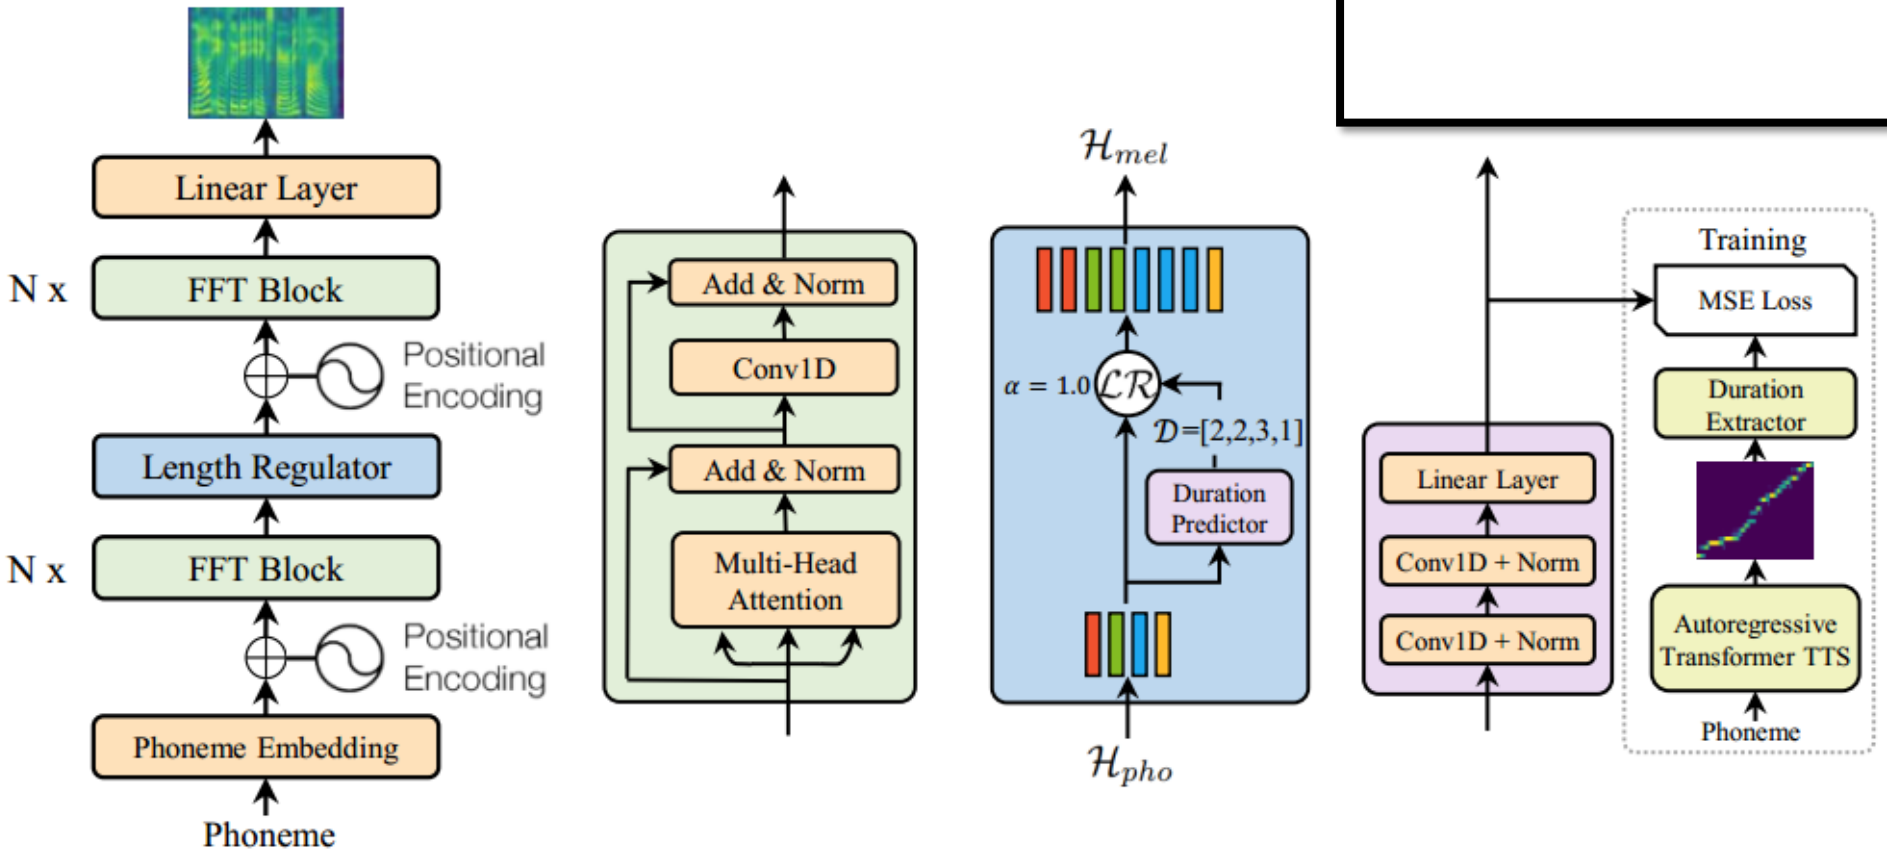

(a) Feed-Forward Transformer (b) FFT Block (c) Length Regulator (d) Duration Predictor

Scaled Dot-Product Attention, Self Attention

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

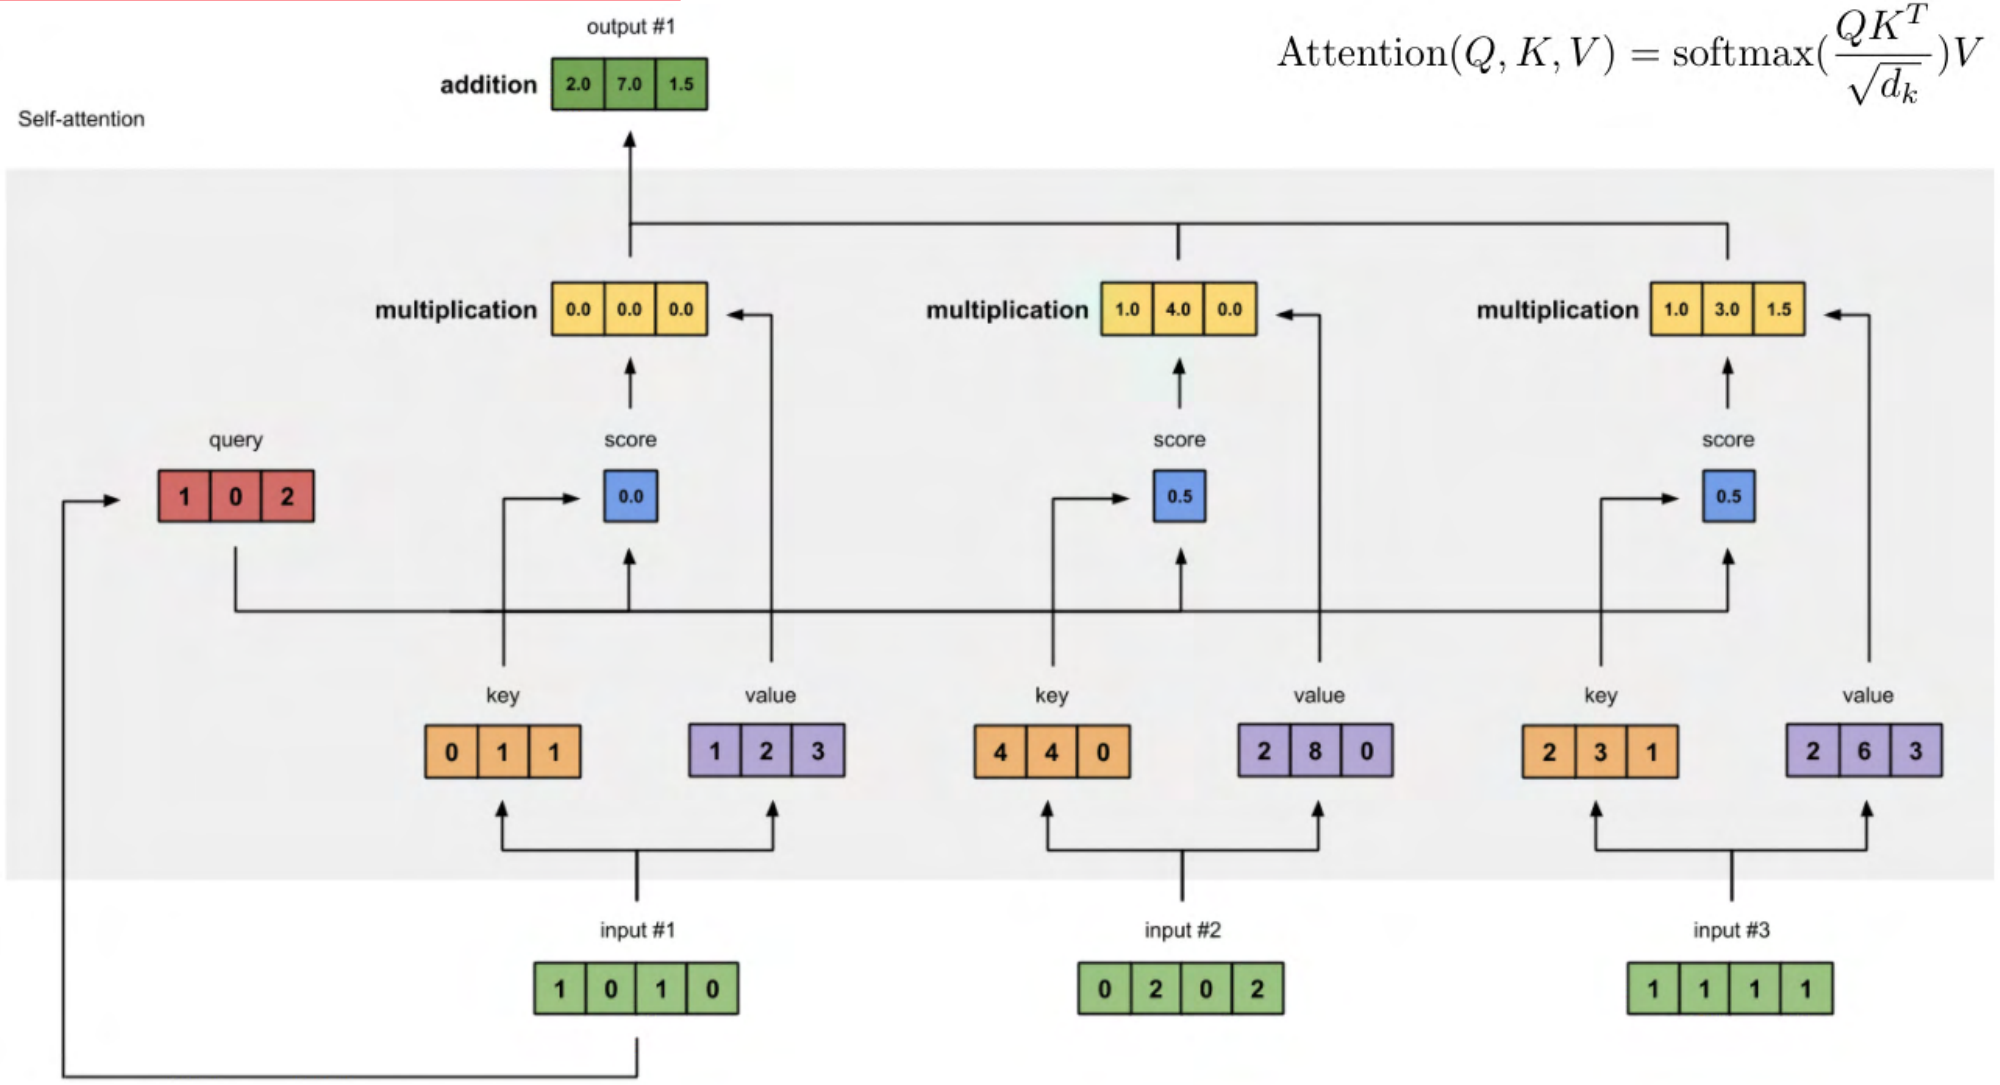

Positional Encoding

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$

$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

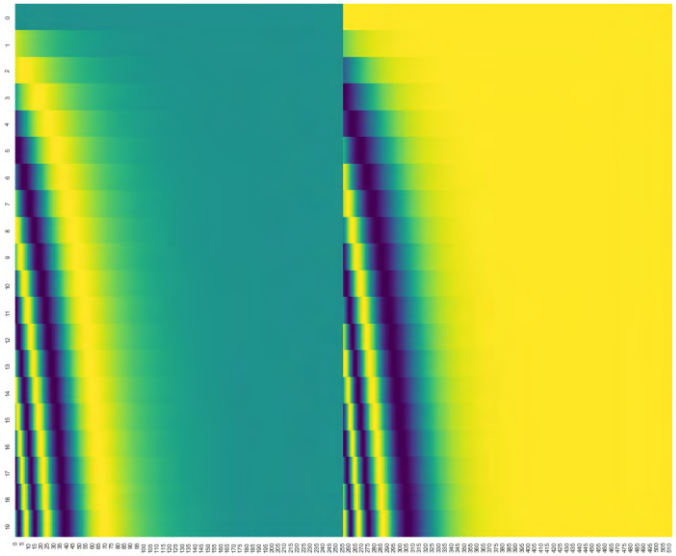

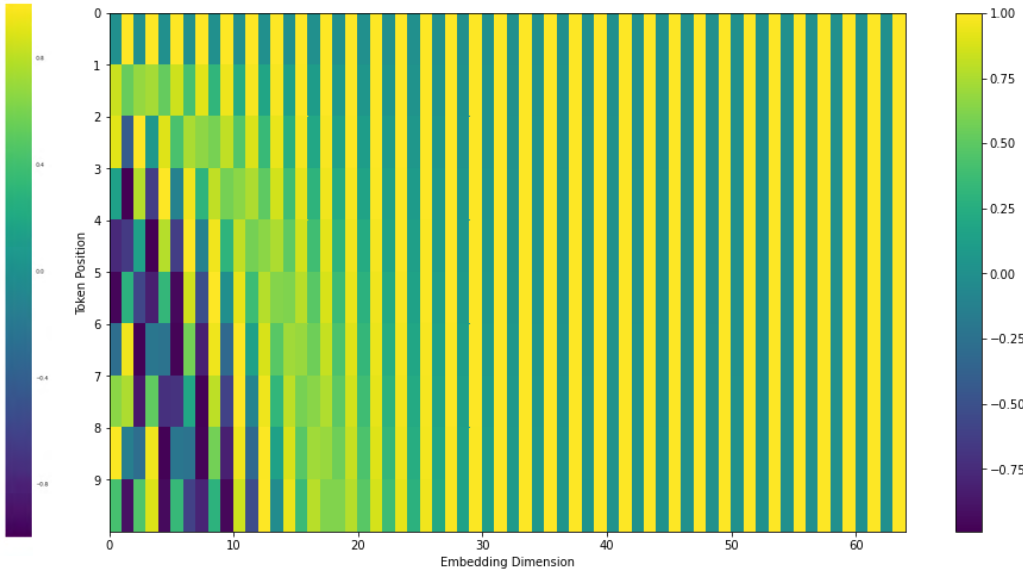

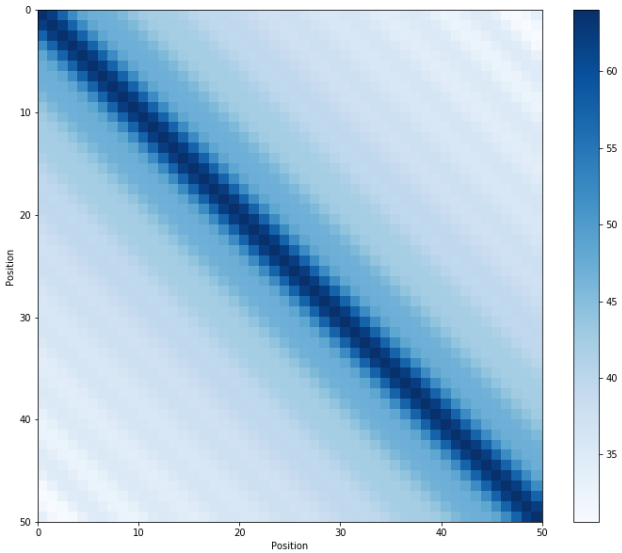

Где взять фонемное выравнивание?

Обучить такотрон

Montreal Forced Aligner (https://github.com/MontrealCorpusTools/Montreal-Forced-Aligner)
или (https://github.com/pettarin/forced-alignment-tools)

Tacotron2

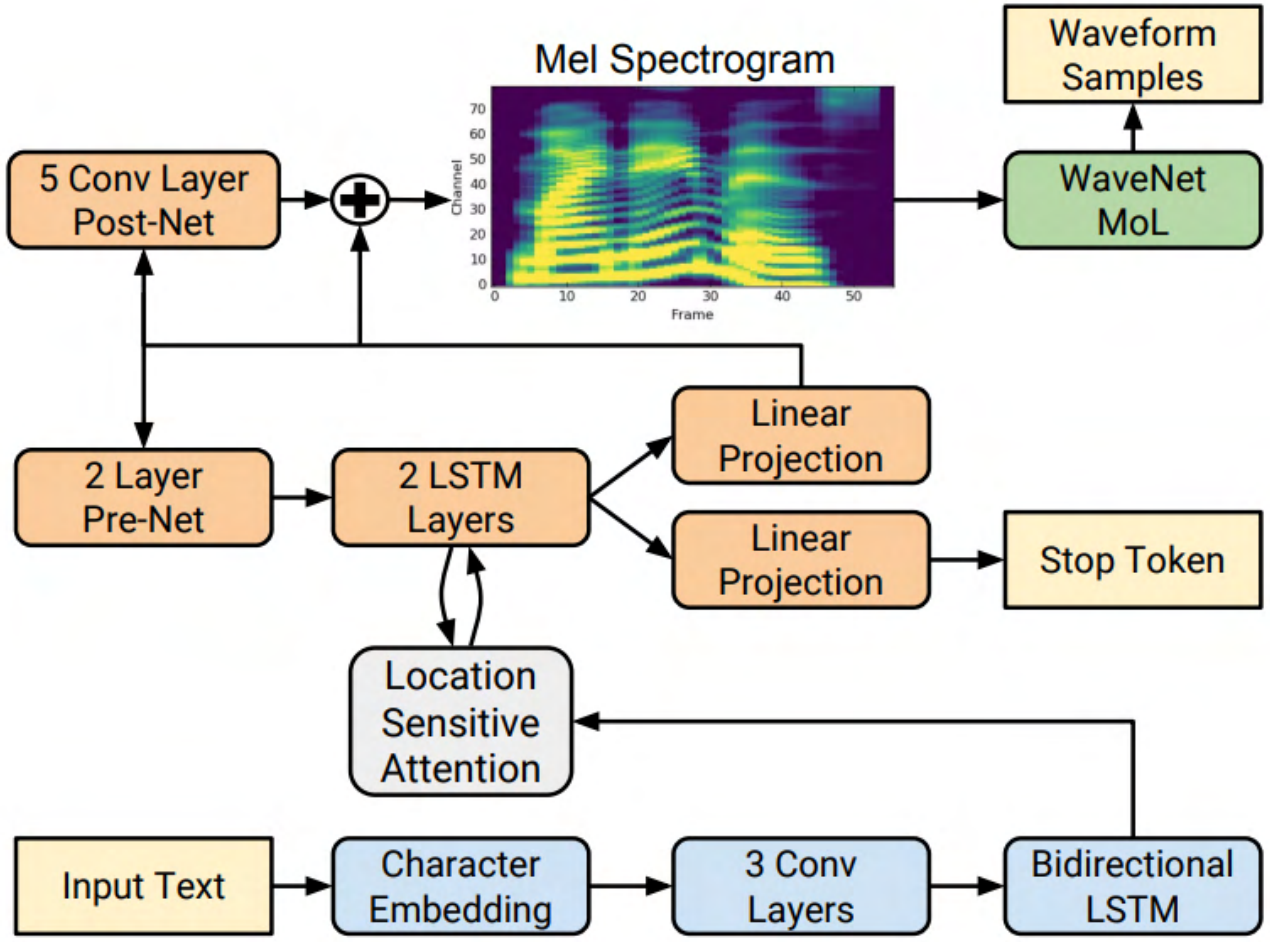
Mel Spectrogram
Waveform Samples
5 Conv Layer Post-Net
WaveNet MoL
Channel
Frame
Linear Projection
2 Layer Pre-Net
2 LSTM Layers
Linear Projection
Stop Token
Location Sensitive Attention
Input Text
Character Embedding
3 Conv Layers
Bidirectional LSTM

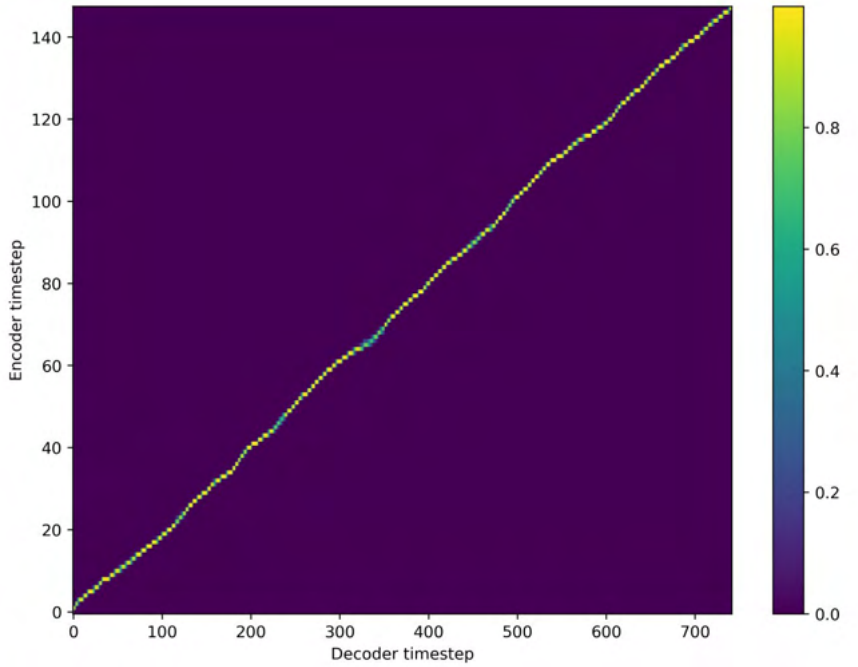
Encoder timestep
Decoder timestep

FastSpeech

Достоинства:

- Высокое качество речи, но требуется тонкая настройка
- Возможен синтез в реальном времени на GPU
- Управление темпом речи их коробки

Недостатки:

- Зависимость от длины предложения
- Квадратичная сложность вычислений и потребления памяти

Как использовать аналогичную идею в Tacotron2?

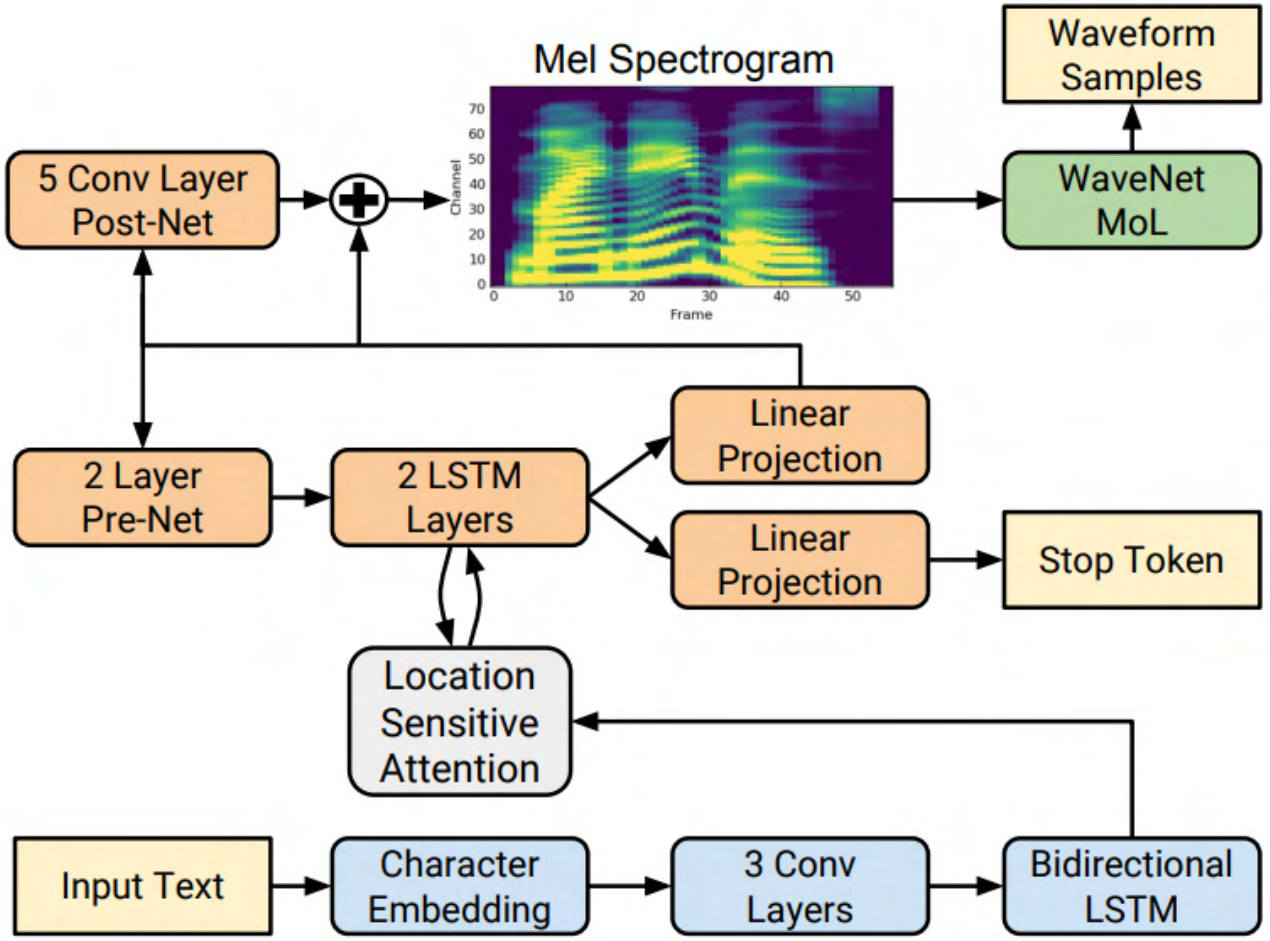

ForwardTacotron, 2019

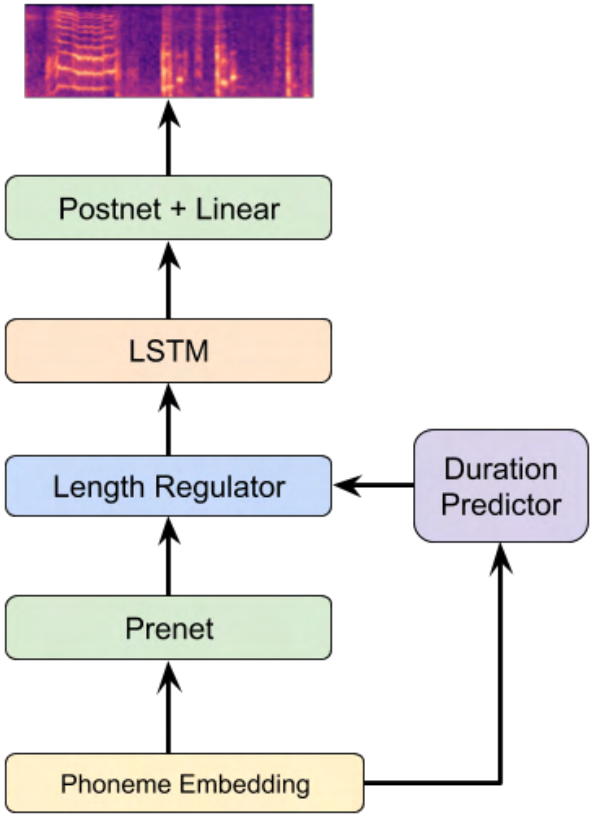

Forward Tacotron

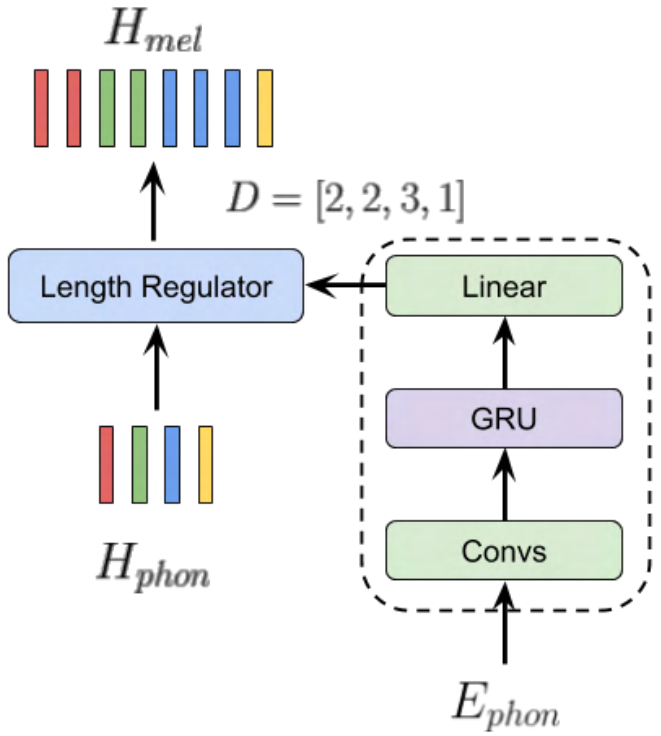

Length Regulator with Duration Predictor

ForwardTacotron

Достоинства:

- Высокое качество речи, сопоставимое с такотроном
- Быстрый инференс на GPU
- Управление темпом речи из коробки
- Работает с текстом любой длины

Недостатки:

- Медленное обучение
- Может зажевывать короткие фонемы

FastSpeech2, 2020

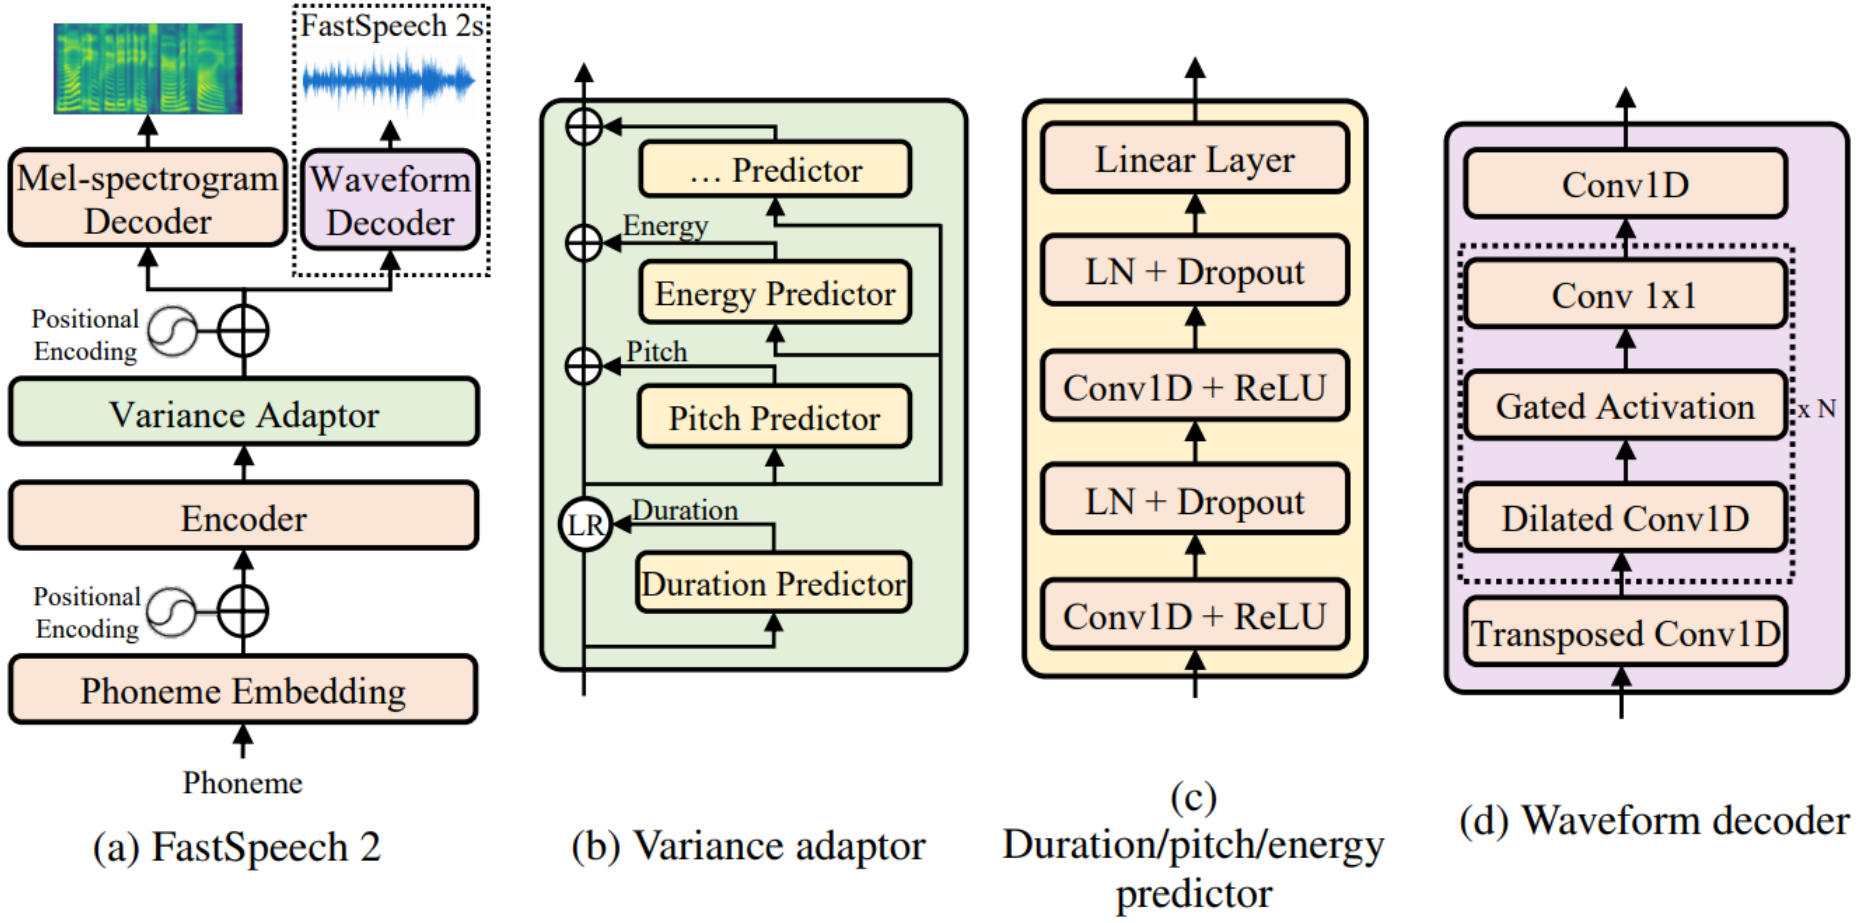

Как подсчитать pitch?

PyWORLD: https://github.com/JeremyCCHsu/Python-Wrapper-for-World-Vocoder

REAPER: https://github.com/google/REAPER

CREPE: https://github.com/maxrmorrison/torchcrepe

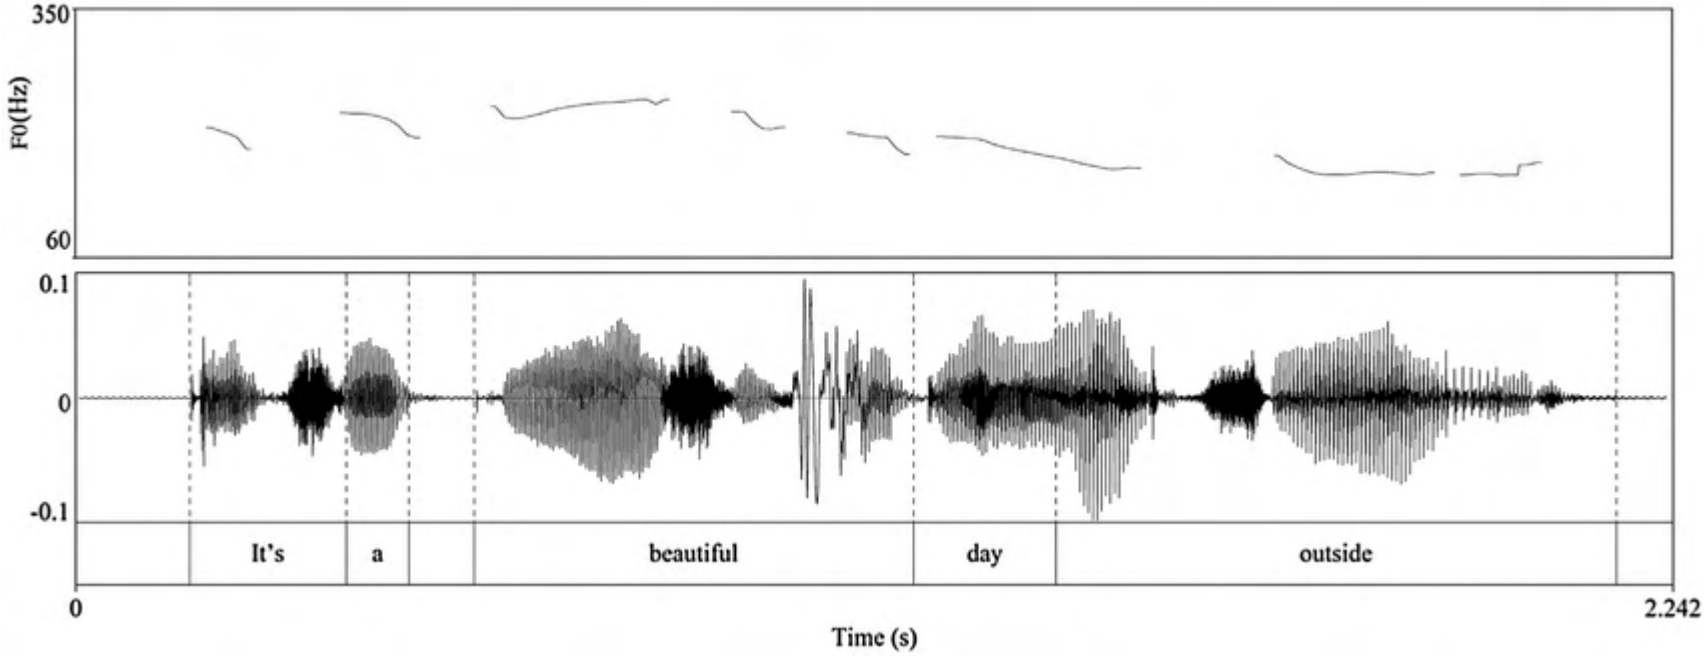

Glow-TTS, 2020

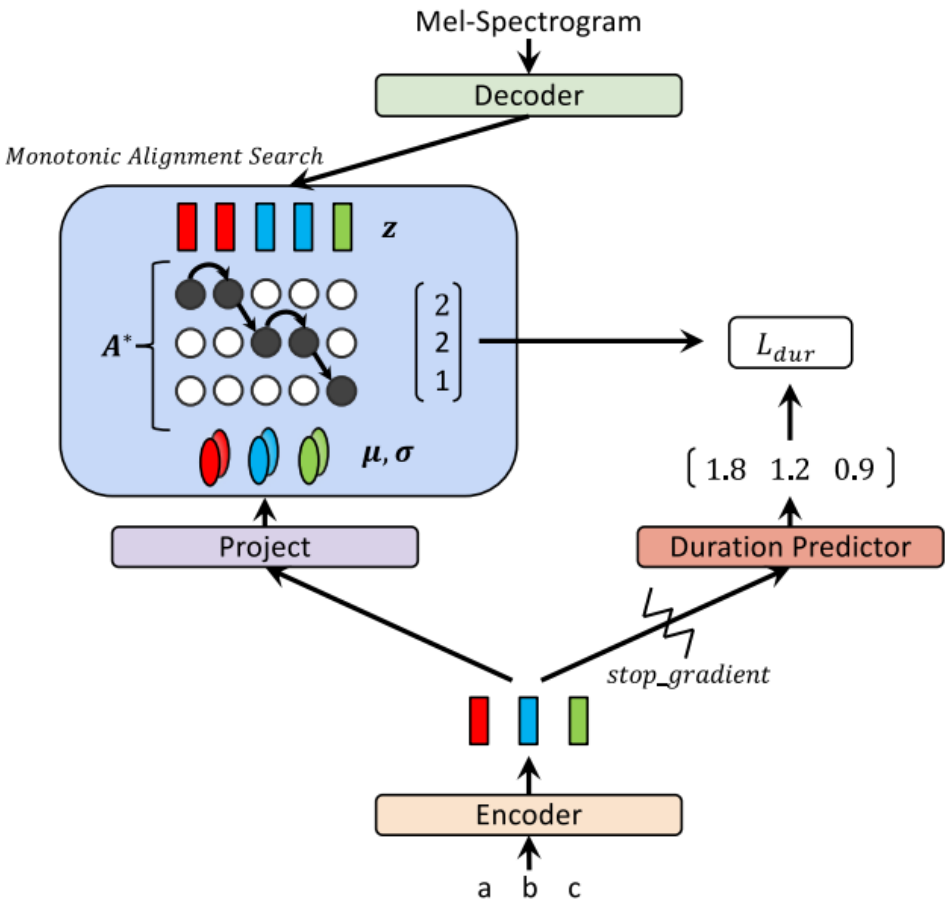

(a) An abstract diagram of the training procedure.

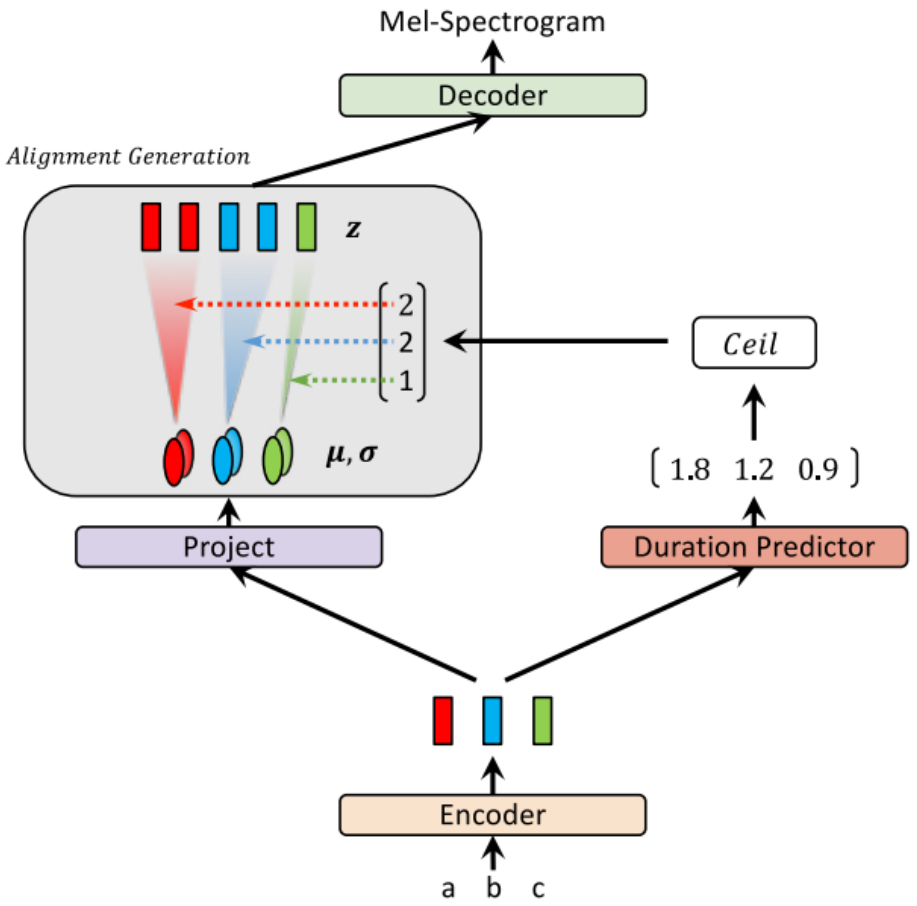

(b) An abstract diagram of the inference procedure.

Multispeaker TTS

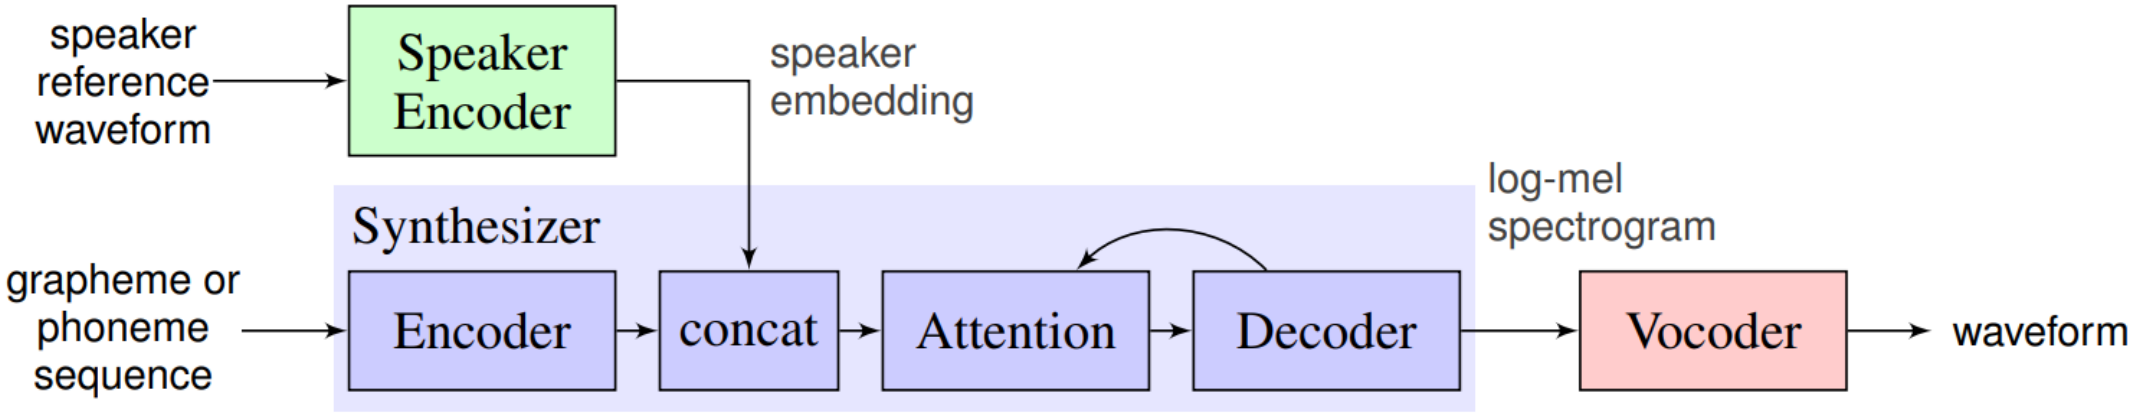

Как кодировать спикеров?

Индексы

Обучаемые эмбеддинги

Bio-эмбеддинги (https://github.com/resemble-ai/Resemblyzer)

Global Style Tokens

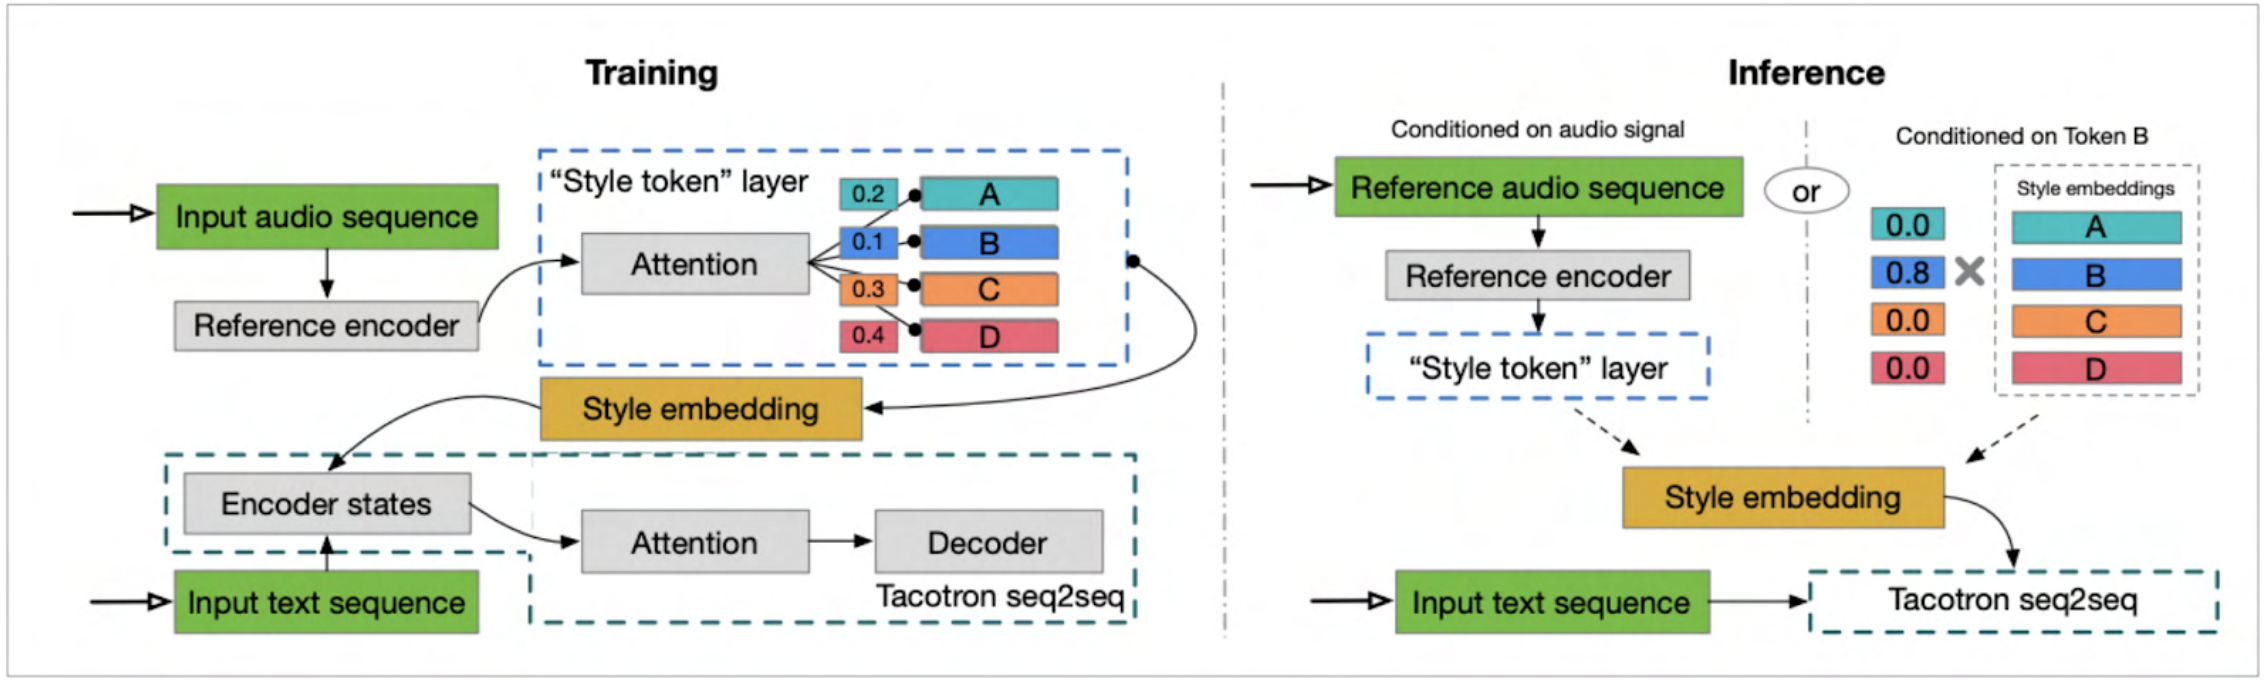

Scaled Dot-Product Attention, Self Attention

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

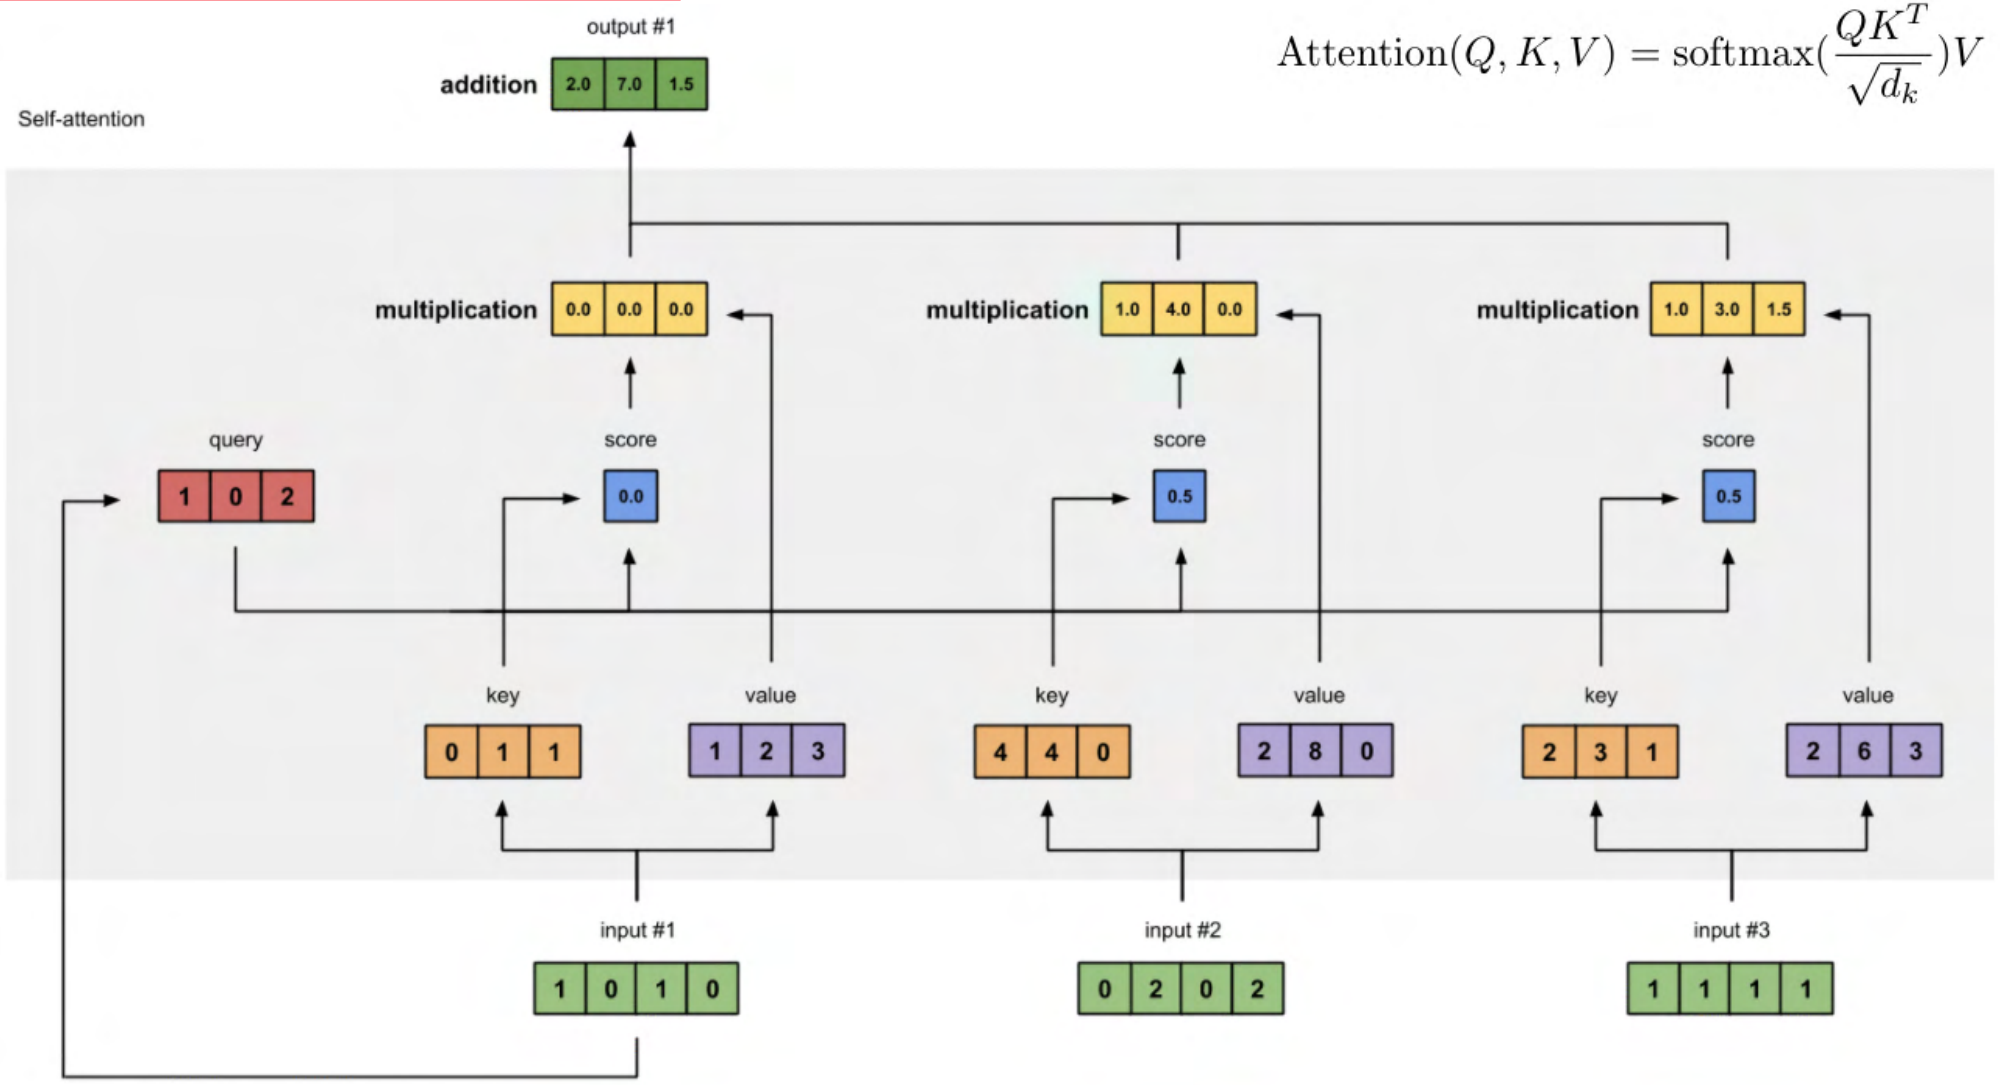

Variational Autoencoders

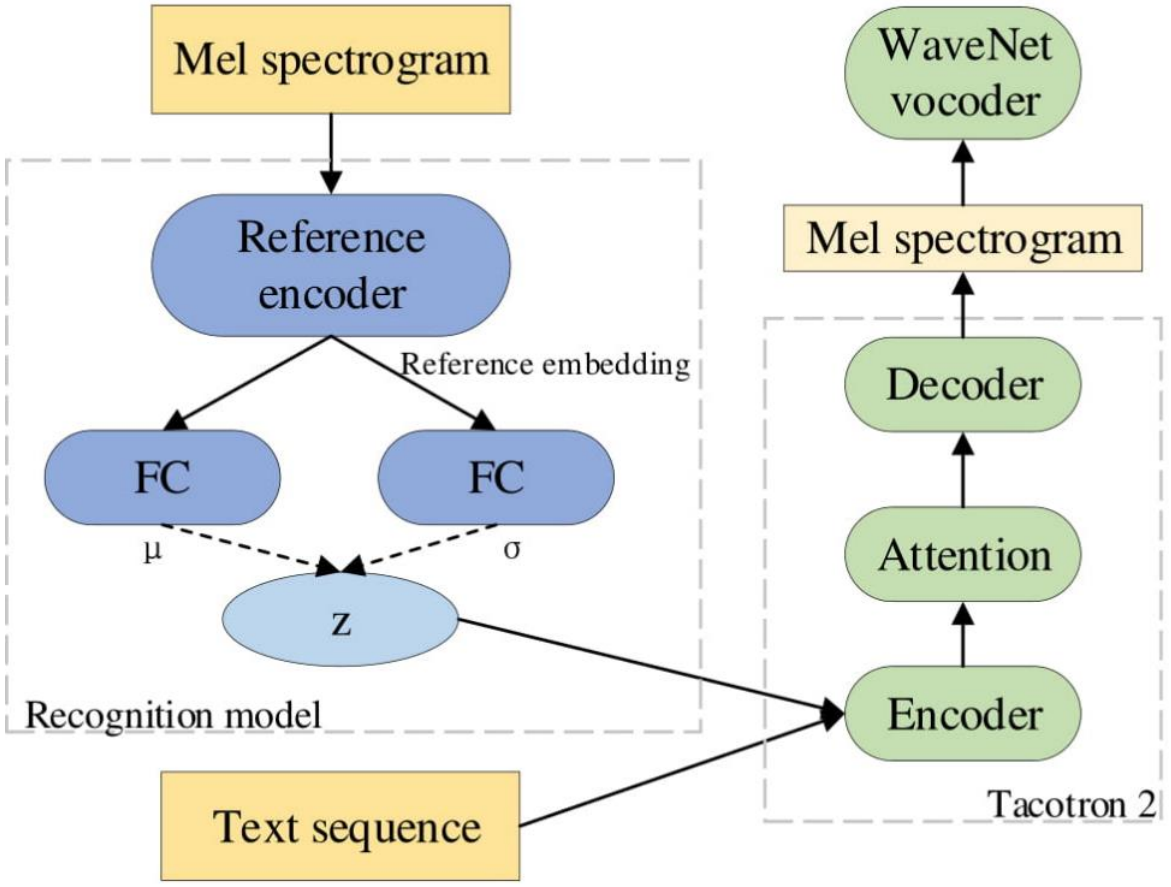

Variational Autoencoders

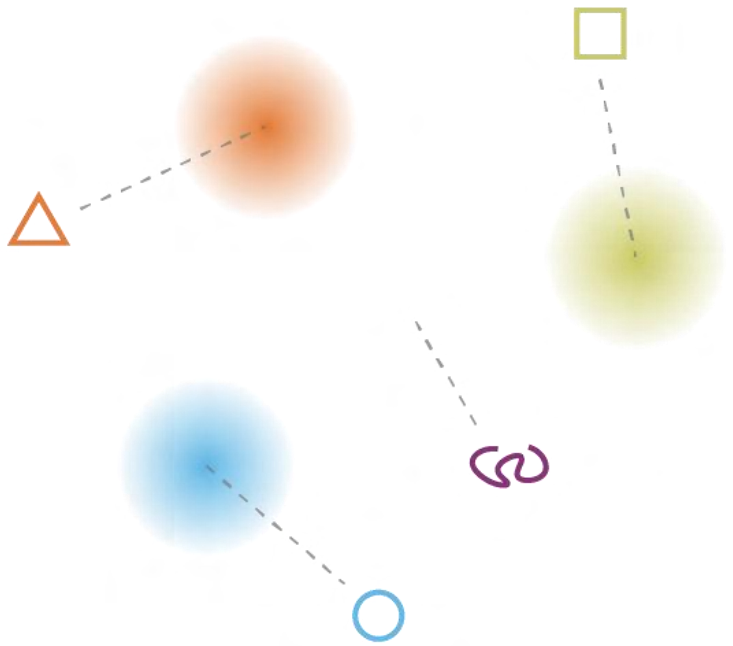

what can happen without regularisation

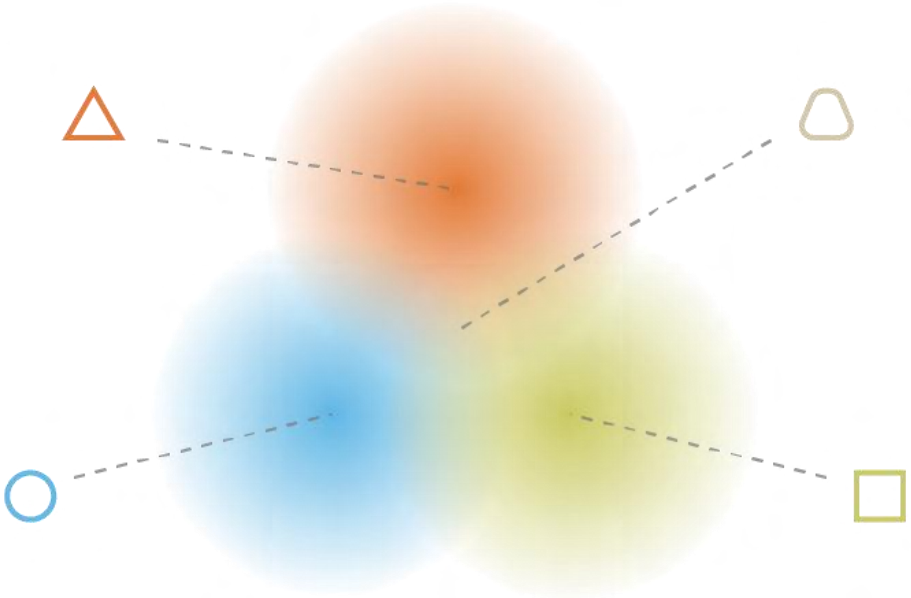

what we want to obtain with regularisation

https://towardsdatascience.com/understanding-variational-autoencoders-vaes-f70510919f73

Variational Autoencoders

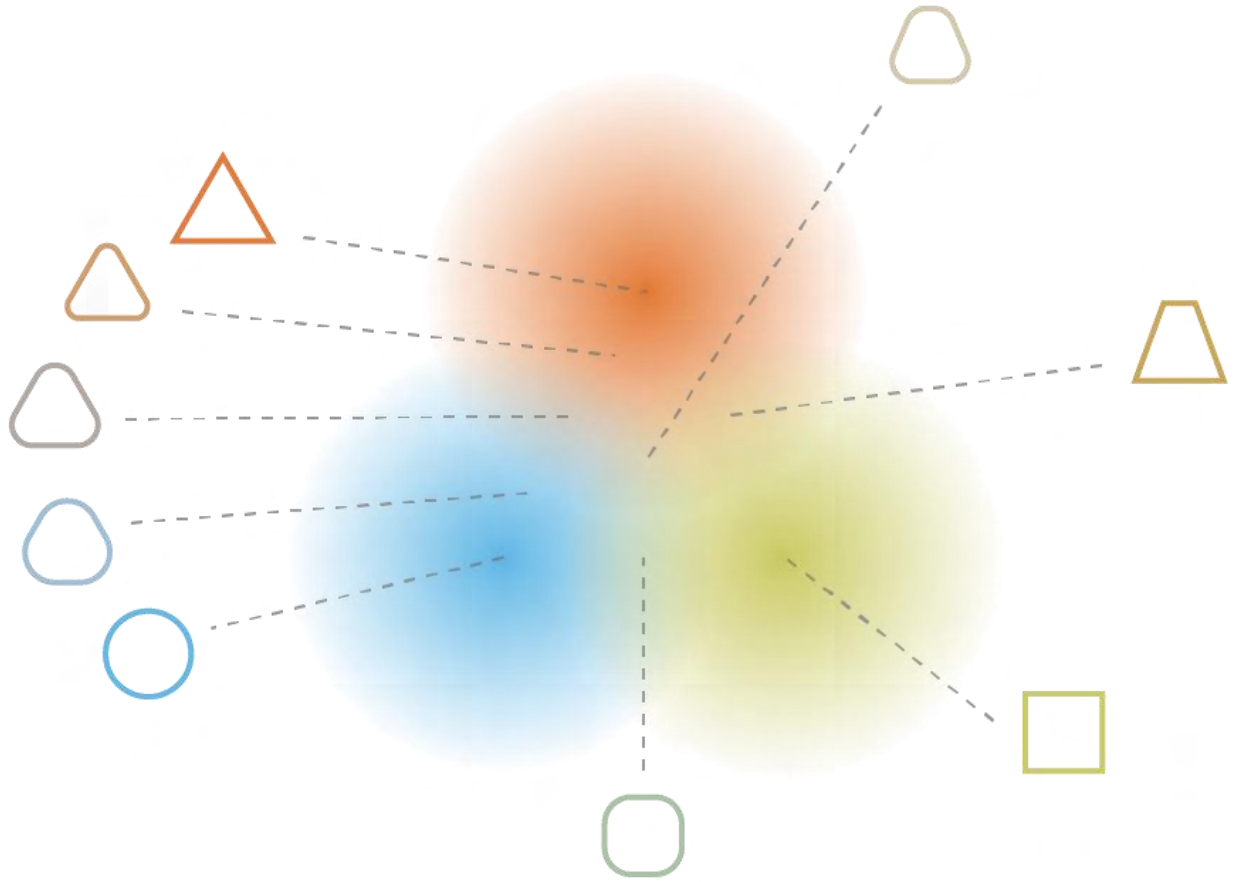

https://towardsdatascience.com/understanding-variational-autoencoders-vaes-f70510919f73

Variational Autoencoders

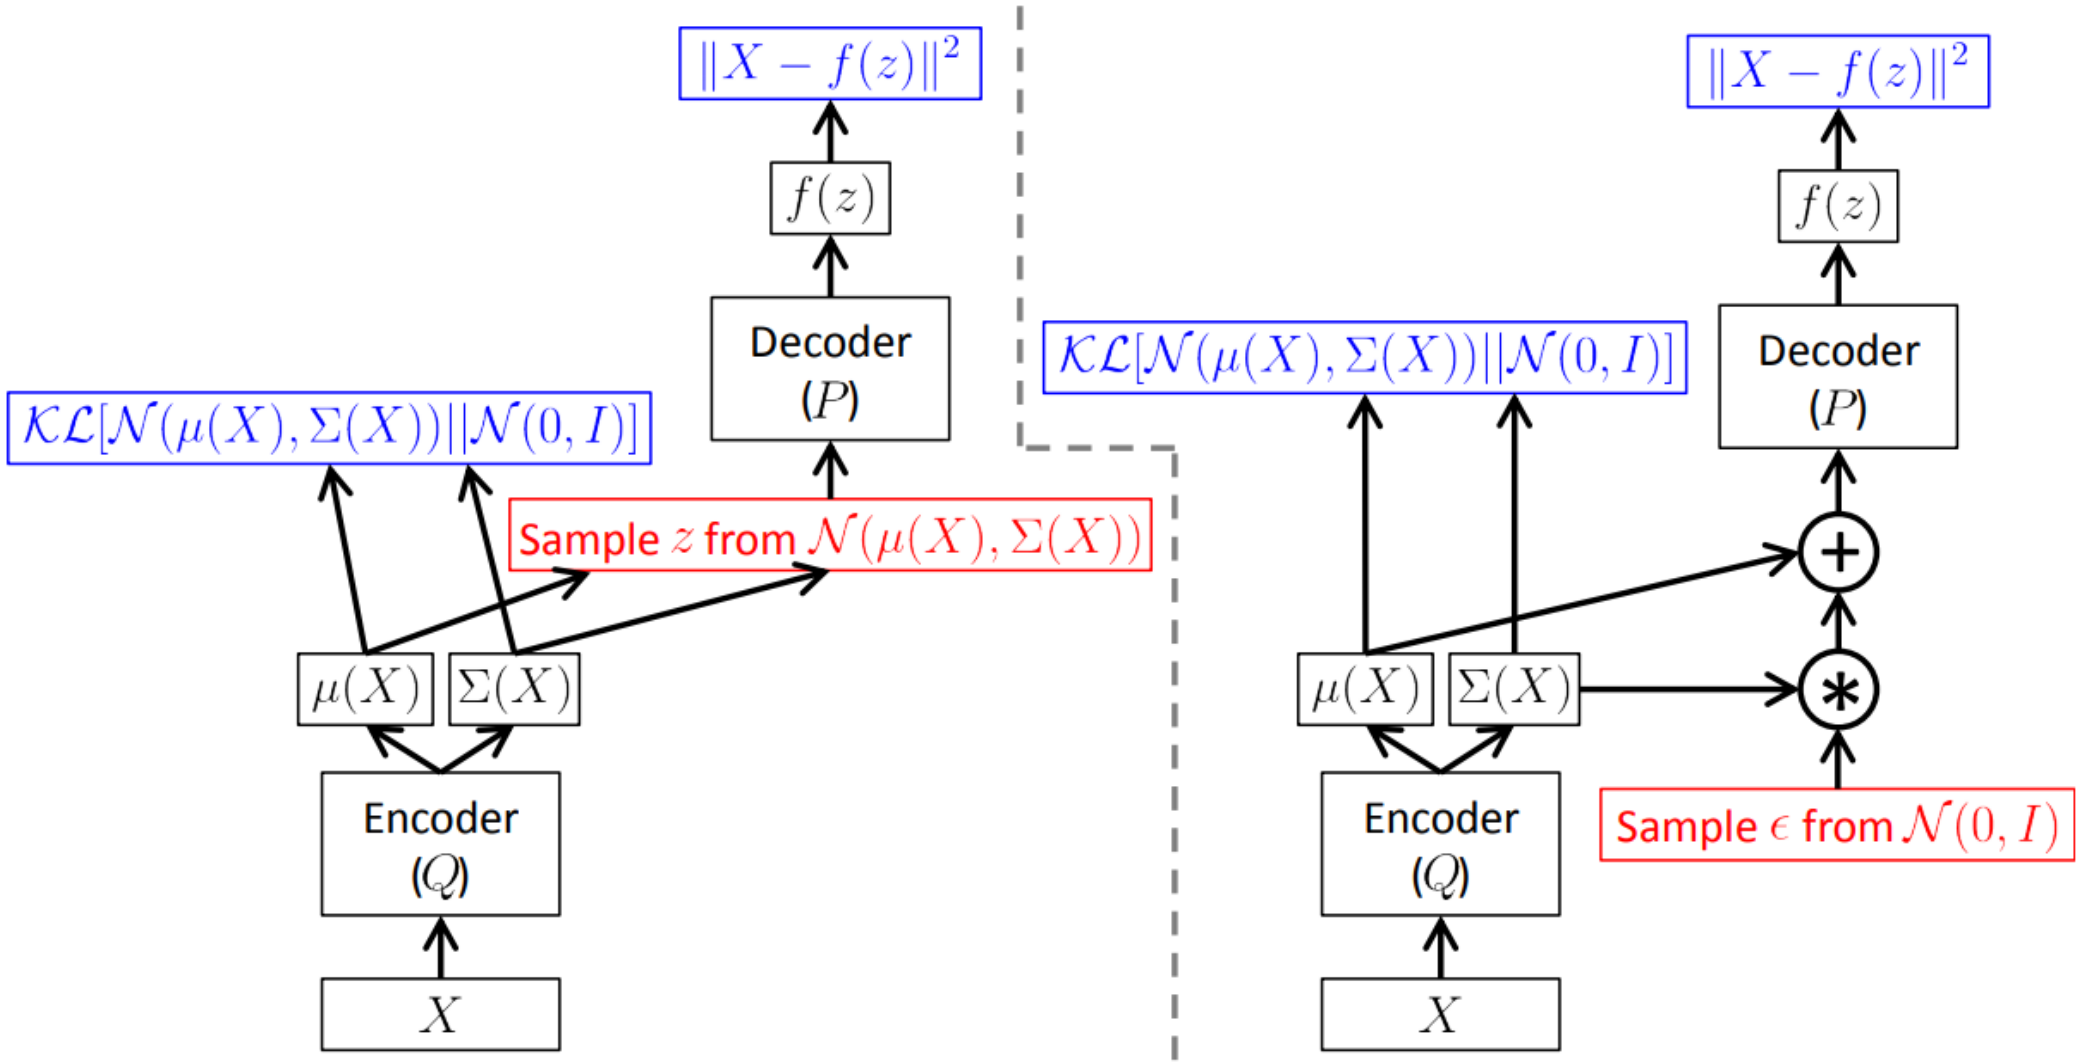

https://arxiv.org/pdf/1606.05908.pdf

SSML-разметка

Speech Synthesis Markup Language (https://www.w3.org/TR/speech-synthesis11)

Я отойду на минутку. <break time="5000"/> Вы еще здесь?

<say-as stress="2"> Перепрофилирование </say-as>

<say-as interpret-as="telephone">2222230</say-as>

<prosody rate="0.5"> Надо есть, чтобы быстро бегать. </prosody>

Это <emphasis level="strong"> огромный </emphasis> банковский счёт.

Спасибо за внимание!